final AA

February 16, 2021

Autora: Helena Antich Homar

Asignatura: Aprendizaje automático

Ejercicio: Práctica final: Dataset de Airbnb Fecha de entrega: 17 Febrero de 2021

Descripción del programa: Este programa analiza y limpia los datos del fichero de Airbnb

1 Librerías y directorios

A continuación vamos a cargar todas las librerías a utilizar en el programa y a determinar el directorio de trabajo para poder leer los datos.

Para modificar el directorio de trabajo, en el que se ubica el fichero de datos y una imagen auxiliar (adjuntada), hay que modificar la variable working_directory.

```
import os
import numpy as np
import pandas as pd
import seaborn as sns
from scipy import stats
import matplotlib.pyplot as plt
from sklearn.feature_extraction.text import CountVectorizer
from sklearn.preprocessing import StandardScaler
from sklearn.model_selection import train_test_split
```

```
[2]: #%% Directories

working_directory = '/Users/Helena/Documents/MASTER MUSI/AA - ML - Aprendizaje⊔

→automático/FINAL' #cambiar para poder realizar el cargado de los datos y la⊔

→imagen auxiliar

os.chdir(working_directory)

path_data = os.path.join(os.getcwd(), 'airbnb.csv') # datos utilizados para el⊔

→entrenamiento del modelo

path_img_map = os.path.join(os.getcwd(), 'map.png') # mapa para la⊔

→representación de los datos sobre la isla de Mallorca
```

2 Preprocesado de los datos

En este apartado trataremos los datos para optimizar el entrenamiento de la IA que se realizará al final.

A continuación cargamos los datos y vemos una breve descripción:

```
[3]: ### Loading data
df_airbnb_raw = pd.read_csv(path_data)
df_airbnb = df_airbnb_raw.copy()
#df_airbnb.head()
df_airbnb.info()
```

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 17608 entries, 0 to 17607
Data columns (total 74 columns):

#	Column	Non-Null Count	Dtype
0	id	17608 non-null	int64
1	listing_url	17608 non-null	object
2	scrape_id	17608 non-null	int64
3	last_scraped	17608 non-null	object
4	name	17607 non-null	object
5	description	17393 non-null	object
6	neighborhood_overview	8213 non-null	object
7	picture_url	17608 non-null	object
8	host_id	17608 non-null	int64
9	host_url	17608 non-null	object
10	host_name	17606 non-null	object
11	host_since	17606 non-null	object
12	host_location	17572 non-null	object
13	host_about	11696 non-null	object
14	host_response_time	15862 non-null	object
15	host_response_rate	15862 non-null	object
16	host_acceptance_rate	16098 non-null	object
17	host_is_superhost	17606 non-null	object
18	host_thumbnail_url	17606 non-null	object
19	host_picture_url	17606 non-null	object
20	host_neighbourhood	364 non-null	object
21	host_listings_count	17606 non-null	float64
22	host_total_listings_count	17606 non-null	float64
23	host_verifications	17608 non-null	object
24	host_has_profile_pic	17606 non-null	object
25	host_identity_verified	17606 non-null	object
26	neighbourhood	8213 non-null	object
27	neighbourhood_cleansed	17608 non-null	object
28	neighbourhood_group_cleansed	0 non-null	float64
29	latitude	17608 non-null	float64

20	longitudo	17600 17	£7+ <i>6</i> 4
30	longitude	17608 non-null	
31	property_type	17608 non-null	0
32	room_type	17608 non-null	0
33	accommodates	17608 non-null	int64
34	bathrooms	0 non-null	float64
35	bathrooms_text	17600 non-null	object
36	bedrooms	17333 non-null	float64
37	beds	17511 non-null	float64
38	amenities	17608 non-null	object
39	price	17608 non-null	object
40	minimum_nights	17608 non-null	int64
41	maximum_nights	17608 non-null	int64
42	minimum_minimum_nights	17608 non-null	int64
43	maximum_minimum_nights	17608 non-null	int64
44	minimum_maximum_nights	17608 non-null	int64
45	maximum_maximum_nights	17608 non-null	int64
46	minimum_nights_avg_ntm	17608 non-null	float64
47	maximum_nights_avg_ntm	17608 non-null	float64
48	calendar_updated	0 non-null	float64
49	has_availability	17608 non-null	object
50	availability_30	17608 non-null	•
51	availability_60	17608 non-null	int64
52	availability_90	17608 non-null	int64
53	availability_365	17608 non-null	int64
54	calendar_last_scraped	17608 non-null	
55	number_of_reviews	17608 non-null	int64
56	number_of_reviews_ltm	17608 non-null	int64
57	number_of_reviews_130d	17608 non-null	
58	first_review	11173 non-null	
59	last_review	11173 non-null	_
60	review_scores_rating	10957 non-null	float64
61	review_scores_accuracy	10951 non-null	
62	review_scores_cleanliness	10953 non-null	float64
63	review_scores_checkin	10949 non-null	float64
64	review_scores_communication	10949 non-null	
65			
	review_scores_location	10950 non-null	
66	review_scores_value	10949 non-null	
67	license	11431 non-null	0
68	instant_bookable	17608 non-null	3
69	calculated_host_listings_count	17608 non-null	int64
70	calculated_host_listings_count_entire_homes	17608 non-null	int64
71	calculated_host_listings_count_private_rooms	17608 non-null	int64
72	calculated_host_listings_count_shared_rooms	17608 non-null	int64
73	reviews_per_month	11173 non-null	float64
	es: float64(19), int64(21), object(34)		
memo	ry usage: 9.9+ MB		

2.1 Eliminación de columnas nulas

Viendo que hay columnas que son todo "null" podemos eliminarlas directamente, ya que no aportan información.

```
[4]: df_airbnb = df_airbnb.drop(columns =__
      →['calendar_updated','bathrooms','neighbourhood_group_cleansed'])
     df_airbnb.head()
[4]:
            id
                                         listing_url
                                                           scrape_id last_scraped
     0
         11547
                 https://www.airbnb.com/rooms/11547
                                                      20200919153121
                                                                       2020-09-21
      100831 https://www.airbnb.com/rooms/100831
                                                      20200919153121
                                                                       2020-09-21
     1
     2 105891 https://www.airbnb.com/rooms/105891
                                                      20200919153121
                                                                       2020-09-20
                https://www.airbnb.com/rooms/106833
     3 106833
                                                      20200919153121
                                                                       2020-09-20
     4 130669
                https://www.airbnb.com/rooms/130669
                                                      20200919153121
                                                                       2020-09-20
                                                name
     0
                               My home at the beach
     1
                  HOUSE IN MALLORCA - WiFi(ET-3045)
     2
        VILLAGE HOUSE WITH POOL: IDEAL FOR FAMILIES
     3
                  Villa with a big pool in Mallorca
     4
                               Room great apartment
                                               description
        Sun, joy, relax, quality, beach & peace. <br />...
     1 <b>The space</b><br />House situated in a quie...
     2 The house is a street on the outskirts of the ...
     3 <b>The space</b><br />This is a restored old b...
     4 Located in a residential neighbourhood and 10m...
                                    neighborhood overview
     0
                                                       NaN
     1
                                                       NaN
     2
        The village's population does not reach two th...
     3
       Located in the center of the city, within minu...
                                               picture_url host_id \
      https://a0.muscache.com/pictures/494126/8c151b...
                                                            42942
     1 https://a0.muscache.com/pictures/675527/72b329...
                                                           529151
     2 https://a0.muscache.com/pictures/1036816/f36ce...
                                                           549192
     3 https://a0.muscache.com/pictures/710218/98134c...
                                                           551974
     4 https://a0.muscache.com/pictures/866653/58dc48...
                                                           643065
                                        host_url
                                                  ... review_scores_communication \
         https://www.airbnb.com/users/show/42942
     0
                                                                             10.0
     1 https://www.airbnb.com/users/show/529151
                                                                             10.0
```

```
2 https://www.airbnb.com/users/show/549192 ...
                                                                        10.0
3 https://www.airbnb.com/users/show/551974
                                                                        10.0
4 https://www.airbnb.com/users/show/643065
                                                                         NaN
  review_scores_location review_scores_value
                                                license instant_bookable
0
                    10.0
                                         10.0
                                                    NaN
                                                                        f
                    10.0
                                         10.0
                                               ETV-3045
1
                                                                        t
2
                     9.0
                                         10.0
                                               ETV/6127
                                                                        t
                                          9.0
3
                     9.0
                                                ET/1961
                                                                        f
4
                     NaN
                                          {\tt NaN}
                                                    NaN
                                                                        t
  \verb|calculated_host_listings_count_entire_homes| \\
0
1
                                1
                                                                             1
2
                                2
                                                                             2
3
                                1
                                                                             1
                                2
4
                                                                             0
  calculated_host_listings_count_private_rooms
0
                                              0
1
2
                                              0
3
                                              0
                                              2
4
  calculated_host_listings_count_shared_rooms reviews_per_month
1
                                             0
                                                             1.47
2
                                             0
                                                             0.14
3
                                             0
                                                             0.09
4
                                             0
                                                              NaN
```

[5 rows x 71 columns]

2.2 Tratamiento de la columna precio

Además el precio, que es la variable a predecir, es de tipo "objeto" y debería ser de tipo valor, incluso para hace el estudio de outliers.

```
[5]: df_airbnb.price = df_airbnb.price.str.replace("$","").str.replace(",","").

→astype(float)

df_airbnb.price.dtype

df_airbnb.price.head()
```

```
[5]: 0 89.0
1 175.0
```

```
2   140.0
3   200.0
4   110.0
Name: price, dtype: float64
```

Ahora que el precio es del tipo número de coma flotante, veamos un resumen estadístico de esta columna:

```
[6]: df_airbnb.price.describe()
```

```
17608.000000
[6]: count
     mean
                 244.383561
                 409.958169
     std
                   0.00000
     min
     25%
                 110.000000
     50%
                 179.000000
     75%
                 275.000000
              20736.000000
     max
```

Name: price, dtype: float64

Dado que el mínimo es un "0" absoluto, tiene que haber un valor al menos que no tenga ningún precio. Este objeto sin precio puede desplazar la media y complicar el análisis mientras que en la realidad no aporta información. Por ello lo eliminamos.

```
[7]: df_airbnb[df_airbnb.price == 0.]
    df_airbnb = df_airbnb[df_airbnb.price != 0.]
    df_airbnb.price.describe()
```

```
[7]: count
              17607.000000
     mean
                 244.397441
     std
                 409.965674
                  10.000000
     min
     25%
                 110.000000
     50%
                 179.000000
     75%
                 275.000000
     max
              20736.000000
```

Name: price, dtype: float64

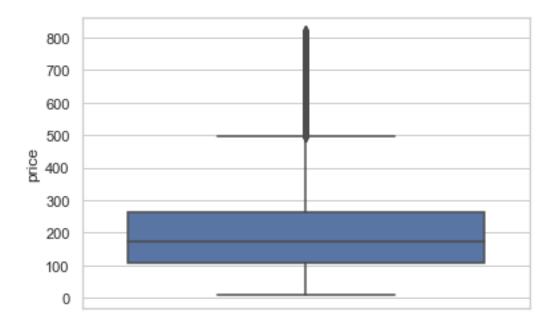
2.3 Análisis y eliminación de outliers¹

Teniendo en cuenta la desviación estándar, vamos a filtrar el dataframe para eliminar outliers analizando la distribución estadística del precio (boxplot) y la distribución por cuantiles (probplot).

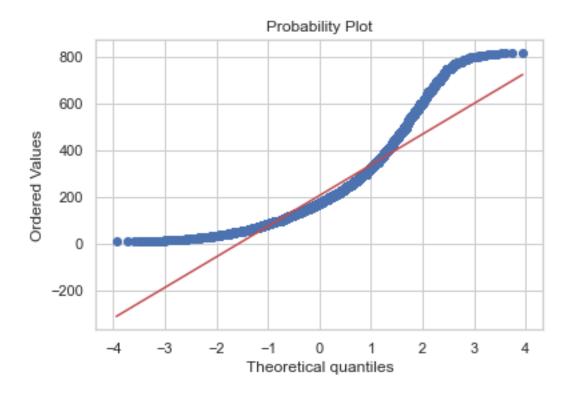
```
[8]: std = df_airbnb.price.describe()[2]
df = df_airbnb.loc[(df_airbnb.price <= 2*std )]
sns.set_theme(style="whitegrid")</pre>
```

¹A lo largo del procesado de las columnas se ha ido realizando este estudio a modo de monitorización del dataset.

```
ax = sns.boxplot(y="price", data=df)
```



```
[9]: stats.probplot(df.price, plot=sns.mpl.pyplot)
```



Habiendo analizado las distribuciones nos hemos quedado con el 95,4% de los datos. Lo que equivale a dos veces la desviación estándar. Se conservan algunos outliers para poder precedecir ciertos comportamientos anómalos con el modelo.

2.4 Tratamiento de columnas y variables

A continuación vamos a seguir tratando las columnas del dataset. Para empezar, leyendo las primeras filas del dataset, podemos determinar si es posible utilizar la información que hay en las columnas.

```
[10]: df.columns
      df.head()
[10]:
             id
                                          listing_url
                                                             scrape_id last_scraped
      0
          11547
                  https://www.airbnb.com/rooms/11547
                                                       20200919153121
                                                                         2020-09-21
                 https://www.airbnb.com/rooms/100831
         100831
                                                        20200919153121
                                                                         2020-09-21
      1
                 https://www.airbnb.com/rooms/105891
      2
         105891
                                                       20200919153121
                                                                         2020-09-20
                 https://www.airbnb.com/rooms/106833
         106833
                                                       20200919153121
                                                                         2020-09-20
                 https://www.airbnb.com/rooms/130669
         130669
                                                       20200919153121
                                                                         2020-09-20
                                                 name
                                                       \
      0
                                 My home at the beach
      1
                   HOUSE IN MALLORCA - WiFi(ET-3045)
```

```
2
   VILLAGE HOUSE WITH POOL: IDEAL FOR FAMILIES
3
             Villa with a big pool in Mallorca
4
                           Room great apartment
                                           description \
   Sun, joy, relax, quality, beach & peace. <br />...
  <br/>
<br/>
<br/>
<br/>
<br/>
<br/>
House situated in a quie...
2 The house is a street on the outskirts of the ...
3 <b>The space</b><br />This is a restored old b...
4 Located in a residential neighbourhood and 10m...
                                neighborhood_overview
0
                                                    NaN
                                                    NaN
1
2
   The village's population does not reach two th...
3
  Located in the center of the city, within minu...
                                           picture_url host_id \
 https://a0.muscache.com/pictures/494126/8c151b...
                                                         42942
1 https://a0.muscache.com/pictures/675527/72b329...
                                                        529151
2 https://a0.muscache.com/pictures/1036816/f36ce...
                                                        549192
3 https://a0.muscache.com/pictures/710218/98134c...
                                                        551974
4 https://a0.muscache.com/pictures/866653/58dc48...
                                                        643065
                                     host_url
                                               ... review scores communication
0
    https://www.airbnb.com/users/show/42942
                                                                           10.0
1 https://www.airbnb.com/users/show/529151
                                                                          10.0
2 https://www.airbnb.com/users/show/549192
                                                                          10.0
3 https://www.airbnb.com/users/show/551974
                                                                          10.0
4 https://www.airbnb.com/users/show/643065
                                                                           NaN
  review_scores_location review_scores_value
                                                  license instant_bookable
0
                     10.0
                                          10.0
                                                      NaN
                                                                          f
                     10.0
                                          10.0
                                                ETV-3045
1
                                                                          t
2
                      9.0
                                          10.0 ETV/6127
                                                                          t
                                                 ET/1961
3
                      9.0
                                           9.0
                                                                          f
                      NaN
                                           {\tt NaN}
                                                      NaN
  {\tt calculated\_host\_listings\_count\_calculated\_host\_listings\_count\_entire\_homes}
0
1
                                 1
                                                                                1
2
                                 2
                                                                                2
3
                                 1
                                                                                1
4
                                 2
                                                                                0
```

calculated_host_listings_count_private_rooms \

```
0
                                                  0
1
                                                  0
2
                                                  0
3
                                                  0
4
                                                  2
  calculated_host_listings_count_shared_rooms reviews_per_month
0
                                                                  0.93
1
                                                 0
                                                                  1.47
2
                                                 0
                                                                  0.14
3
                                                                  0.09
                                                 0
                                                                   NaN
```

[5 rows x 71 columns]

Ahora vamos a seleccionar las columnas que creemos que pueden ser relevantes. Algunos de los motivos de descarte pueden ser: * Descartamos las columnas, por ejemplo: listing_url, scrape_id, name, description y neighborhood_overview, porque la información de estas columnas se podría encontrar en otras. * Se descartan las columnas, por ejemplo: picture_url, host_id, y host_url, por ser valores aeatorios u arbitrarios asignados a cada hospedaje. * Se eliminan las columnas que se refieren de forma exclusiva al dueño del hospedaje, como nombre o su descripción, que no se refieren al hospedaje o influyen de ninguna manera sobre tiempos de respuesta del comprador.

```
[11]: df = df.drop(columns = [ 'last_scraped', 'host_since', __
    →'host_location','host_name', 'host_about', 'host_thumbnail_url',
    →'host_picture_url', 'listing_url', 'scrape_id', 'name', 'description',

¬'neighborhood_overview','picture_url', 'host_id', 'host_url',

    →'host_response_rate', 'host_acceptance_rate', 'host_neighbourhood',
    →'host_listings_count', 'host_total_listings_count', 'host_verifications',
    → 'host_has_profile_pic', 'host_response_time', 'availability_30', 'availability_60', □
    →'availability_90', 'availability_365', 'minimum_minimum_nights', ⊔
    \hookrightarrow 'maximum_minimum_nights', 'minimum_maximum_nights',
    → 'calculated_host_listings_count_entire_homes', 'calculated_host_listings_count_private_rooms
    df.columns
```

```
[12]: df.head()
[12]:
             id host_is_superhost host_identity_verified
      0
          11547
                                 f
      1
        100831
                                 f
                                                          t
      2 105891
                                 t
                                                          t
      3 106833
                                 f
                                                          t
                                 f
      4 130669
                                                          f
             neighbourhood_cleansed latitude
                                                 longitude
                                                                         property_type
      0
                              Calvià 39.51888
                                                   2.48182
                                                                      Entire apartment
      1
                     Santa Margalida 39.76347
                                                   3.16255
                                                                          Entire house
      2
                  Maria de la Salut 39.66044
                                                                      Entire townhouse
                                                   3.07165
                                                   3.30121
      3
         Sant Llorenç des Cardassar 39.61600
                                                                           Entire villa
      4
                  Palma de Mallorca 39.56478
                                                   2.60333 Private room in apartment
               room_type
                           accommodates bathrooms_text ...
                                                             number_of_reviews \
      O Entire home/apt
                                       2
                                                 1 bath
                                                                            103
      1 Entire home/apt
                                       8
                                                3 baths ...
                                                                             30
      2 Entire home/apt
                                       6
                                                2 baths ...
                                                                             14
         Entire home/apt
                                                                              9
      3
                                       4
                                                 1 bath ...
                                       2
                                                                              0
            Private room
                                                 1 bath
         review_scores_rating review_scores_accuracy review_scores_cleanliness \
      0
                          96.0
                                                  10.0
                                                                                9.0
      1
                         100.0
                                                  10.0
                                                                               10.0
      2
                          97.0
                                                  10.0
                                                                               10.0
                                                                               10.0
      3
                          98.0
                                                  10.0
      4
                           NaN
                                                   NaN
                                                                                NaN
                                review_scores_communication review_scores_location \
         review_scores_checkin
      0
                           10.0
                                                          10.0
                                                                                  10.0
                           10.0
      1
                                                          10.0
                                                                                  10.0
                           10.0
      2
                                                          10.0
                                                                                   9.0
      3
                           10.0
                                                          10.0
                                                                                   9.0
      4
                            NaN
                                                           NaN
                                                                                   NaN
         review_scores_value
                                license
                                          instant_bookable
      0
                         10.0
                                    NaN
      1
                         10.0
                               ETV-3045
                                                          t
      2
                         10.0
                               ETV/6127
                                                          t
      3
                          9.0
                                ET/1961
                                                          f
      4
                          NaN
                                    NaN
```

'review_scores_location', 'review_scores_value', 'license',

'instant_bookable'],

dtype='object')

2.4.1 Columnas de tipo buleano con strings

A continuación trataremos aquellas columnas que tienen valores 'f' o 't' y las convertiremos a valores binarios:

```
[13]: df = df.replace({'t': 1, 'f':0})
```

Columna bathrooms_text A continuación se traduce la columna bathrooms_text a un valor numérico. En primer lugar vemos qué valores deberemos tratar:

En segundo lugar reemplazamos los "medios baños" por 0.5.

dtype=object)

'9.5 baths', '4 shared baths', '8 baths', '0 shared baths', '2.5 shared baths', '11 baths', '9 baths', '3 shared baths', '3.5 shared baths', '12.5 baths', '32 baths', '8.5 baths', '13 shared baths', '12 baths', '10 baths', '13 baths'],

Ahora extraemos el valor numérico que hay dentro del string y lo almacenamos en una nueva columna.

'4 baths', '5 baths', '0.5', '1.5 shared baths', '1 shared bath', '3.5 baths', '6 baths', nan, '6.5 baths', '5.5 baths', '7.5 baths',

```
[16]: df['bathrooms'] = df['bathrooms_text'].str.extract('(\d*\.\d+|\d+)', expand =__
      →False).astype(float)
     df.bathrooms = df.bathrooms.fillna(0)
     df.bathrooms.unique()
[16]: array([ 1. , 3. , 2. , 0. , 1.5, 7. , 4.5, 2.5, 4. , 5. , 0.5,
             3.5, 6., 6.5, 5.5, 7.5, 9.5, 8., 11., 9., 12.5, 32.,
             8.5, 13., 12., 10.])
     Ahora ya se puede eliminar la columna con los strings.
[17]: df = df.drop(columns = ['bathrooms_text'])
     df.columns
[17]: Index(['id', 'host_is_superhost', 'host_identity_verified',
             'neighbourhood_cleansed', 'latitude', 'longitude', 'property_type',
             'room type', 'accommodates', 'bedrooms', 'beds', 'amenities', 'price',
             'minimum_nights', 'maximum_nights', 'has_availability',
             'number_of_reviews', 'review_scores_rating', 'review_scores_accuracy',
             'review_scores_cleanliness', 'review_scores_checkin',
             'review_scores_communication', 'review_scores_location',
             'review_scores_value', 'license', 'instant_bookable', 'bathrooms'],
            dtype='object')
[18]: df.info()
     <class 'pandas.core.frame.DataFrame'>
     Int64Index: 17181 entries, 0 to 17607
     Data columns (total 27 columns):
          Column
                                      Non-Null Count Dtype
         ____
                                       _____
      0
                                       17181 non-null int64
          id
      1
          host_is_superhost
                                       17179 non-null float64
      2
          host_identity_verified
                                       17179 non-null float64
      3
          neighbourhood_cleansed
                                       17181 non-null object
      4
          latitude
                                       17181 non-null float64
      5
          longitude
                                       17181 non-null float64
                                      17181 non-null object
          property_type
      7
          room_type
                                      17181 non-null
                                                      object
      8
          accommodates
                                      17181 non-null int64
      9
          bedrooms
                                       16911 non-null float64
      10 beds
                                       17097 non-null float64
      11
         amenities
                                       17181 non-null object
      12
         price
                                       17181 non-null
                                                      float64
      13 minimum_nights
                                      17181 non-null int64
      14 maximum_nights
                                      17181 non-null int64
      15 has_availability
                                      17181 non-null int64
```

17181 non-null int64

16 number_of_reviews

```
17 review_scores_rating
                                 10833 non-null
                                                float64
 18 review_scores_accuracy
                                 10829 non-null
                                                float64
 19
    review_scores_cleanliness
                                 10831 non-null
                                                float64
 20 review_scores_checkin
                                 10827 non-null
                                                float64
 21 review scores communication 10829 non-null float64
 22 review scores location
                                 10828 non-null float64
 23 review scores value
                                 10827 non-null
                                                float64
24 license
                                 11184 non-null
                                                object
 25 instant_bookable
                                 17181 non-null
                                                int64
                                 17181 non-null float64
 26 bathrooms
dtypes: float64(15), int64(7), object(5)
memory usage: 3.7+ MB
```

2.4.2 Columna license

La siguiente columna a tratar será la de licencia. Vamos a codificar la columna en licencia o no licencia:

```
[19]: df.license.unique()
[19]: array([nan, 'ETV-3045', 'ETV/6127', ..., 'ETV/5754', 'LIZE84/2017',
              '00551ETV'], dtype=object)
[20]: df.license = df.license.fillna(0)
      df.license[df.license != 0] = 1
      df.license.astype(int)
      df.license
[20]: 0
               0
      1
               1
      2
               1
      3
               1
      4
               0
               . .
      17603
               1
      17604
      17605
               1
      17606
      17607
               0
```

Name: license, Length: 17181, dtype: object

Antes de empezar con los tipos de alojamiento o habitación, vamos a realizar una separación de amenities y haremos un conteo de cada uno para las distintas propiedades. Para ello se definirá un nuevo dataframe que luego podremos concatenar con el anterior.

2.4.3 Columna amenities

Para la creación de este dataframe vamos a utilizar la funcion CountVectorizer del paquete scikit-learn. Se ha entendido su funcionamiento a partir de una búsqueda en *stack overflow* y posteriormente de las instrucciones de la librería (enlace).

Esta función permite identificar distintas etiquetas de un *string* y además genera una matriz para identificar las posiciones de éstas. Utilizando estas dos características podemos generar el nuevo data frame.

En primer lugar extraemos la matriz de posiciones y los valores de las etiquetas:

```
[22]: vectorizer = CountVectorizer(tokenizer=lambda row: row.split(','))

matriz = vectorizer.fit_transform(df.amenities)
etiquetas = vectorizer.get_feature_names()
```

Ahora corregimos algunas de las etiquetas, que, por cómo estan construidos los datos, incluyen algunos caracteres que las harán difíciles de utilizar:

```
[23]: for ind, amenit in enumerate(etiquetas):
    amenit_limpias = amenit.replace('"','').replace('[','').replace(']','').
    strip()
    etiquetas[ind] = amenit_limpias
```

Finalmente creamos el dataframe nuevo y borramos las columnas a reemplazar:

```
[24]: df_amenities = pd.DataFrame(matriz.toarray(),columns=etiquetas)
    df_amenities.drop('',axis=1,inplace=True)
    df_amenities.columns
```

Comprobamos si hay columnas duplicadas:

(Para hacerlo más intuitivo, la siguiente línea devuelve un true si hay columnas duplicadas y un false si no las hay)

```
[25]: not(len(df_amenities.columns) == len(df_amenities.columns.unique()))
```

[25]: True

Efectivamente, hay alguna o algunas columnas duplicadas. El paso siguiente es convertir estas

múltiples columnas en una sola, de manera que esta indique si el hospedaje tiene o no esta característica, de esta manera conseguimos columnas que coinciden con la técnica de "OneHotEncoding".

```
[26]: cols = df_amenities.columns.tolist()
    new_df = pd.DataFrame()

for ncol in range(len(cols)):
    col_name = cols[ncol]
    if col_name not in new_df.columns:
        indices = [i for i, x in enumerate(cols) if x == col_name]
        new_df.loc[:,col_name] = df_amenities.iloc[:,indices].sum(axis=1).
    otolist()

new_df[new_df > 0] = 1 #Convertimos a binario
```

Realizamos de nuevo la comprobación, para estar seguros de que no hay duplicados: (En este caso un valor True representa que no hay duplicaciones)

```
[27]: (new_df.columns == new_df.columns.unique()).all()
```

[27]: True

Ahora que tenemos la categoría de amenities tratada, se procede a la agregación de estas columnas al dataframe original y la eliminación de la columna que contenía la información. Ello se realiza mediante una concatenación de columnas ya que no se ha alterado el orden de los índices en todo el proceso.

```
[28]: df = df.drop(columns = ['amenities'])
      df = pd.concat([df, new_df], axis=1)
[29]:
     df.head()
[29]:
               id host_is_superhost host_identity_verified \
      0
          11547.0
                                 0.0
                                                         1.0
      1
       100831.0
                                 0.0
                                                         1.0
      2
                                                         1.0
       105891.0
                                 1.0
      3 106833.0
                                 0.0
                                                         1.0
       130669.0
                                 0.0
                                                         0.0
             neighbourhood_cleansed
                                               longitude
                                                                      property_type
                                     latitude
      0
                             Calvià
                                     39.51888
                                                 2.48182
                                                                    Entire apartment
      1
                                                 3.16255
                    Santa Margalida 39.76347
                                                                        Entire house
      2
                  Maria de la Salut 39.66044
                                                 3.07165
                                                                    Entire townhouse
      3
         Sant Llorenç des Cardassar
                                     39.61600
                                                 3.30121
                                                                        Entire villa
                  Palma de Mallorca 39.56478
                                                 2.60333
                                                         Private room in apartment
               room_type accommodates bedrooms ... trash compactor
                                                                        tv
        Entire home/apt
                                   2.0
                                             1.0
                                                                  0.0 1.0
```

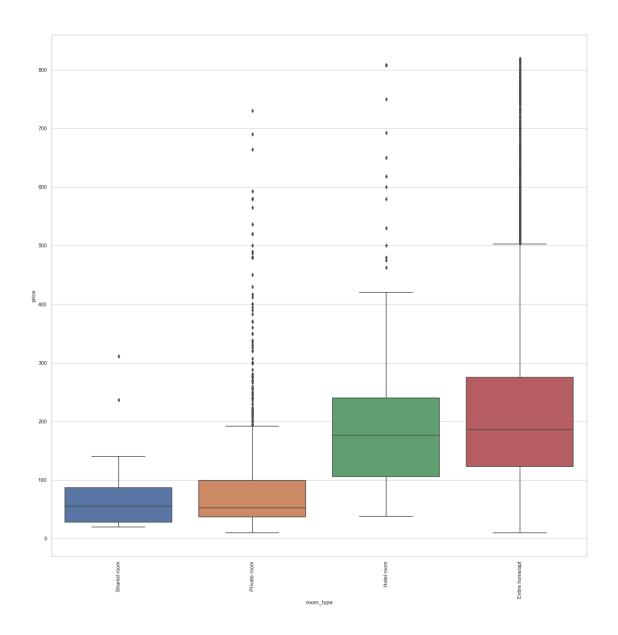
```
1 Entire home/apt
                              8.0
                                         4.0 ...
                                                              0.0 1.0
2 Entire home/apt
                              6.0
                                         3.0 ...
                                                              0.0 1.0
3 Entire home/apt
                              4.0
                                         2.0 ...
                                                              0.0 1.0
      Private room
                              2.0
                                         1.0 ...
                                                              0.0 1.0
   walk in closet
                   washer
                            waterfront
                                        wifi window guards wine cooler
0
              0.0
                       1.0
                                   0.0
                                          1.0
                                                          0.0
                                                                       0.0
              0.0
                       1.0
                                   0.0
                                          1.0
                                                          0.0
                                                                       0.0
1
2
                                          1.0
              0.0
                       1.0
                                   0.0
                                                          0.0
                                                                       0.0
3
              0.0
                       0.0
                                   0.0
                                          1.0
                                                          0.0
                                                                       0.0
                                          1.0
4
              0.0
                       1.0
                                   0.0
                                                          0.0
                                                                       0.0
   wood-burning fireplace
                            terrace
0
                       0.0
                                0.0
                       0.0
                                0.0
1
2
                       0.0
                                0.0
3
                       0.0
                                0.0
4
                       0.0
                                0.0
```

[5 rows x 154 columns]

2.4.4 Columnas de tipo de alojamiento y propiedad

A continuación se procede a analizar cuál de las columnas property_type o room_type conviene más tratar y posteriormente se aplicará "OneHotEncoding. Para ello, analizamos las dos columnas.

En primer lugar analizamos room_type:



[32]:	Entire home/apt	Hotel room	Private room	Shared room
0	1	0	0	0
1	1	0	0	0
2	1	0	0	0
3	1	0	0	0
4	0	0	1	0
•••	•••	•••	•••	
17603	1	0	0	0
17604	1	0	0	0

17605	1	0	0	0
17606	0	0	1	0
17607	1	0	0	0

[17603 rows x 4 columns]

4

Con el nuevo dataframe creado únicamente falta eliminar la columna previa y añadir las nuevas ya codificadas.

```
[33]: df = df.drop(columns = ['room_type'])
      df = pd.concat([df, df_rooms], axis=1)
      df.head()
[33]:
               id host_is_superhost host_identity_verified \
          11547.0
                                   0.0
      1
         100831.0
                                                            1.0
         105891.0
                                   1.0
                                                            1.0
      3 106833.0
                                   0.0
                                                            1.0
      4 130669.0
                                   0.0
                                                            0.0
             neighbourhood_cleansed
                                       latitude
                                                 longitude
                                                                          property_type
      0
                                                    2.48182
                              Calvià
                                      39.51888
                                                                       Entire apartment
      1
                     Santa Margalida
                                      39.76347
                                                    3.16255
                                                                           Entire house
      2
                  Maria de la Salut
                                      39.66044
                                                    3.07165
                                                                       Entire townhouse
      3
         Sant Llorenç des Cardassar
                                      39.61600
                                                    3.30121
                                                                           Entire villa
                   Palma de Mallorca
                                       39.56478
                                                    2.60333
                                                            Private room in apartment
         accommodates
                        bedrooms
                                                               window guards
                                  beds
                                            waterfront
                                                         wifi
                   2.0
      0
                             1.0
                                    1.0
                                                    0.0
                                                          1.0
                                                                          0.0
      1
                   8.0
                             4.0
                                    7.0
                                                    0.0
                                                          1.0
                                                                          0.0
      2
                   6.0
                             3.0
                                    4.0
                                                    0.0
                                                          1.0
                                                                          0.0
      3
                   4.0
                             2.0
                                    4.0
                                                    0.0
                                                          1.0
                                                                          0.0
                   2.0
                             1.0
                                    2.0
                                                    0.0
                                                          1.0
                                                                          0.0
         wine cooler
                       wood-burning fireplace
                                                terrace
                                                          Entire home/apt Hotel room \
                  0.0
                                           0.0
      0
                                                     0.0
                                                                         1
                                                                                      0
                                           0.0
                                                                                      0
                  0.0
                                                     0.0
                                                                         1
      1
      2
                                           0.0
                                                     0.0
                                                                                      0
                  0.0
                                                                         1
      3
                  0.0
                                           0.0
                                                     0.0
                                                                         1
                                                                                      0
                 0.0
                                           0.0
                                                     0.0
                                                                                      0
         Private room
                        Shared room
      0
                     0
                                  0
      1
                     0
                                  0
      2
                     0
                                  0
      3
                     0
                                   0
```

[5 rows x 157 columns]

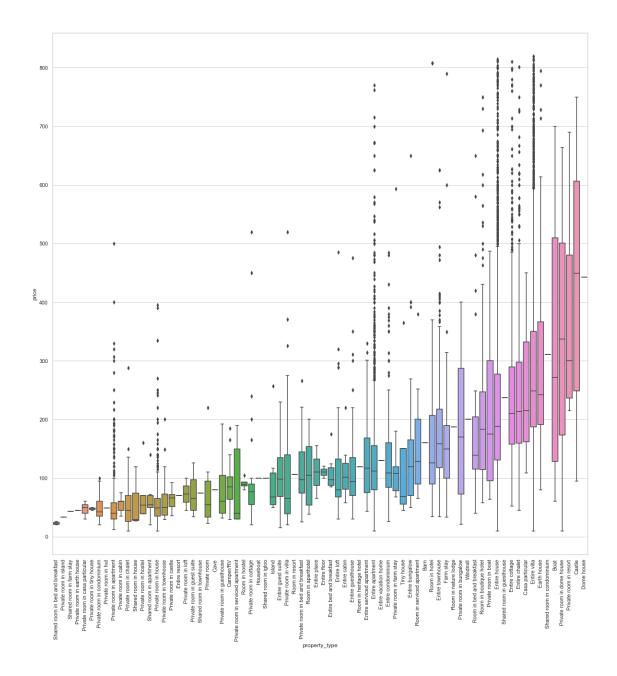
En segundo lugar analizamos property_type:

Text(1, 0, 'Private room in island'),

```
[34]: df.property_type.unique()
[34]: array(['Entire apartment', 'Entire house', 'Entire townhouse',
             'Entire villa', 'Private room in apartment', 'Entire guesthouse',
             'Private room in guest suite', 'Private room in villa',
             'Entire loft', 'Entire cottage', 'Castle', 'Entire condominium',
             'Room in boutique hotel', 'Private room', 'Private room in house',
             'Entire chalet', 'Entire cabin', nan,
             'Private room in condominium', 'Entire guest suite',
             'Private room in boat', 'Private room in cottage', 'Camper/RV',
             'Boat', 'Private room in townhouse', 'Private room in hostel',
             'Private room in bed and breakfast', 'Entire serviced apartment',
             'Private room in guesthouse', 'Shared room in apartment',
             'Farm stay', 'Room in serviced apartment',
             'Room in bed and breakfast', 'Private room in chalet',
             'Entire bungalow', 'Room in hotel', 'Island',
             'Shared room in igloo', 'Private room in farm stay',
             'Shared room in bed and breakfast', 'Entire bed and breakfast',
             'Entire place', 'Room in aparthotel', 'Entire vacation home',
             'Private room in bungalow', 'Shared room in house', 'Earth house',
             'Entire floor', 'Room in hostel', 'Room in resort',
             'Room in nature lodge', 'Private room in cabin', 'Tiny house',
             'Shared room in condominium', 'Shared room in guesthouse',
             'Private room in hut', 'Entire resort', 'Windmill', 'Dome house',
             'Private room in loft', 'Private room in serviced apartment',
             'Private room in earth house', 'Private room in casa particular',
             'Casa particular', 'Cave', 'Private room in castle',
             'Private room in resort', 'Private room in dome house',
             'Private room in tiny house', 'Houseboat',
             'Shared room in farm stay', 'Room in heritage hotel',
             'Private room in island', 'Shared room in townhouse', 'Barn'],
            dtype=object)
[35]: fig, ax = plt.subplots(figsize=(20, 20))
      sorted_average = df.groupby('property_type').mean().
      →sort_values('price',ascending=True)
      ax = sns.boxplot(x="property_type", y="price", data=df, order=sorted_average.
       →index)
      ax.set_xticklabels(ax.get_xticklabels(),rotation=90)
[35]: [Text(0, 0, 'Shared room in bed and breakfast'),
```

```
Text(2, 0, 'Shared room in farm stay'),
Text(3, 0, 'Private room in earth house'),
Text(4, 0, 'Private room in casa particular'),
Text(5, 0, 'Private room in tiny house'),
Text(6, 0, 'Private room in condominium'),
Text(7, 0, 'Private room in hut'),
Text(8, 0, 'Private room in apartment'),
Text(9, 0, 'Private room in cabin'),
Text(10, 0, 'Private room in chalet'),
Text(11, 0, 'Shared room in house'),
Text(12, 0, 'Private room in hostel'),
Text(13, 0, 'Shared room in apartment'),
Text(14, 0, 'Private room in house'),
Text(15, 0, 'Private room in townhouse'),
Text(16, 0, 'Private room in castle'),
Text(17, 0, 'Entire resort'),
Text(18, 0, 'Private room in loft'),
Text(19, 0, 'Private room in guest suite'),
Text(20, 0, 'Shared room in townhouse'),
Text(21, 0, 'Private room'),
Text(22, 0, 'Cave'),
Text(23, 0, 'Private room in guesthouse'),
Text(24, 0, 'Camper/RV'),
Text(25, 0, 'Private room in serviced apartment'),
Text(26, 0, 'Room in hostel'),
Text(27, 0, 'Private room in cottage'),
Text(28, 0, 'Houseboat'),
Text(29, 0, 'Shared room in igloo'),
Text(30, 0, 'Island'),
Text(31, 0, 'Entire guest suite'),
Text(32, 0, 'Private room in villa'),
Text(33, 0, 'Room in resort'),
Text(34, 0, 'Private room in bed and breakfast'),
Text(35, 0, 'Room in aparthotel'),
Text(36, 0, 'Entire place'),
Text(37, 0, 'Entire floor'),
Text(38, 0, 'Entire bed and breakfast'),
Text(39, 0, 'Entire loft'),
Text(40, 0, 'Entire cabin'),
Text(41, 0, 'Entire guesthouse'),
Text(42, 0, 'Room in heritage hotel'),
Text(43, 0, 'Entire serviced apartment'),
Text(44, 0, 'Entire apartment'),
Text(45, 0, 'Entire vacation home'),
Text(46, 0, 'Entire condominium'),
Text(47, 0, 'Private room in farm stay'),
Text(48, 0, 'Tiny house'),
```

```
Text(49, 0, 'Entire bungalow'),
Text(50, 0, 'Room in serviced apartment'),
Text(51, 0, 'Barn'),
Text(52, 0, 'Room in hotel'),
Text(53, 0, 'Entire townhouse'),
Text(54, 0, 'Farm stay'),
Text(55, 0, 'Room in nature lodge'),
Text(56, 0, 'Private room in bungalow'),
Text(57, 0, 'Windmill'),
Text(58, 0, 'Room in bed and breakfast'),
Text(59, 0, 'Room in boutique hotel'),
Text(60, 0, 'Private room in boat'),
Text(61, 0, 'Entire house'),
Text(62, 0, 'Shared room in guesthouse'),
Text(63, 0, 'Entire cottage'),
Text(64, 0, 'Entire chalet'),
Text(65, 0, 'Casa particular'),
Text(66, 0, 'Entire villa'),
Text(67, 0, 'Earth house'),
Text(68, 0, 'Shared room in condominium'),
Text(69, 0, 'Boat'),
Text(70, 0, 'Private room in dome house'),
Text(71, 0, 'Private room in resort'),
Text(72, 0, 'Castle'),
Text(73, 0, 'Dome house')]
```



La columna de tipo de propiedad, aunque intuitivamente tiene relevancia para el análisis, contiene una alta variabilidad y al ver la distribución estadística de los valores por etiqueta no parece un sistema fiable, ni siquiera ordenado por la media del precio agrupado por tipo de propiedad. Por todo esto se decide eliminar la columna.

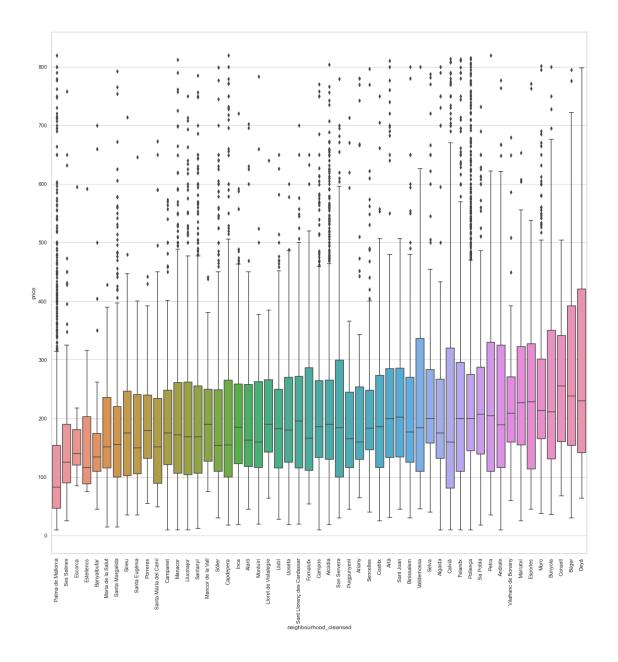
```
[36]: df = df.drop(columns = ['property_type']) #Se elimina la columna descartada
```

2.4.5 Columna neighbourhood_cleansed:

Esta columna accede a las propiedades de "barrio", que son menos localizadas que latitud y longitud. Esta ligera deslocalización puede ser beneficiosa a la hora de aplicar el modelo.

```
[37]: df.neighbourhood_cleansed.unique()
[37]: array(['Calvià', 'Santa Margalida', 'Maria de la Salut',
             'Sant Llorenç des Cardassar', 'Palma de Mallorca', 'Selva',
             'Esporles', 'Banyalbufar', 'Manacor', 'Sa Pobla', 'Alcúdia',
             'Pollença', 'Artà', 'Santanyí', 'Fornalutx', 'Campos', 'Llucmajor',
             'Sineu', 'Lloseta', 'Marratxí', 'Felanitx', 'Llubí', 'Muro',
             'Lloret de Vistalegre', 'Ariany', 'Campanet', 'Capdepera',
             'Puigpunyent', 'Binissalem', 'Valldemossa', 'Algaida',
             'Son Servera', 'Sóller', 'Ses Salines', nan, 'Mancor de la Vall',
             'Andratx', 'Santa María del Camí', 'Inca', 'Costitx', 'Bunyola',
             'Deyá', 'Búger', 'Porreres', 'Alaró', 'Montuïri', 'Escorca',
             'Petra', 'Consell', 'Sencelles', 'Vilafranc de Bonany',
             'Estellencs', 'Sant Joan', 'Santa Eugènia'], dtype=object)
[38]: fig, ax = plt.subplots(figsize=(20, 20))
      sorted_average = df.groupby('neighbourhood_cleansed').mean().
      →sort_values('price',ascending=True)
      ax = sns.boxplot(x="neighbourhood_cleansed", y="price", data=df,__
       →order=sorted_average.index)
      ax.set_xticklabels(ax.get_xticklabels(),rotation=90)
[38]: [Text(0, 0, 'Palma de Mallorca'),
      Text(1, 0, 'Ses Salines'),
       Text(2, 0, 'Escorca'),
       Text(3, 0, 'Estellencs'),
       Text(4, 0, 'Banyalbufar'),
       Text(5, 0, 'Maria de la Salut'),
       Text(6, 0, 'Santa Margalida'),
       Text(7, 0, 'Sineu'),
       Text(8, 0, 'Santa Eugènia'),
       Text(9, 0, 'Porreres'),
       Text(10, 0, 'Santa María del Camí'),
       Text(11, 0, 'Campanet'),
       Text(12, 0, 'Manacor'),
      Text(13, 0, 'Llucmajor'),
       Text(14, 0, 'Santanyi'),
       Text(15, 0, 'Mancor de la Vall'),
       Text(16, 0, 'Sóller'),
       Text(17, 0, 'Capdepera'),
       Text(18, 0, 'Inca'),
       Text(19, 0, 'Alaró'),
```

```
Text(20, 0, 'Montuïri'),
Text(21, 0, 'Lloret de Vistalegre'),
Text(22, 0, 'Llubí'),
Text(23, 0, 'Lloseta'),
Text(24, 0, 'Sant Llorenç des Cardassar'),
Text(25, 0, 'Fornalutx'),
Text(26, 0, 'Campos'),
Text(27, 0, 'Alcúdia'),
Text(28, 0, 'Son Servera'),
Text(29, 0, 'Puigpunyent'),
Text(30, 0, 'Ariany'),
Text(31, 0, 'Sencelles'),
Text(32, 0, 'Costitx'),
Text(33, 0, 'Artà'),
Text(34, 0, 'Sant Joan'),
Text(35, 0, 'Binissalem'),
Text(36, 0, 'Valldemossa'),
Text(37, 0, 'Selva'),
Text(38, 0, 'Algaida'),
Text(39, 0, 'Calvià'),
Text(40, 0, 'Felanitx'),
Text(41, 0, 'Pollença'),
Text(42, 0, 'Sa Pobla'),
Text(43, 0, 'Petra'),
Text(44, 0, 'Andratx'),
Text(45, 0, 'Vilafranc de Bonany'),
Text(46, 0, 'Marratxí'),
Text(47, 0, 'Esporles'),
Text(48, 0, 'Muro'),
Text(49, 0, 'Bunyola'),
Text(50, 0, 'Consell'),
Text(51, 0, 'Búger'),
Text(52, 0, 'Deyá')]
```



Según el boxplot hay una linealidad entre el lugar y la distribución de la media del precio, pese a los outliers. Por tanto, se decide que es una columna de utilidad. A continuación, se trata con la técnica OHE.

```
[39]: df_neigh = pd.get_dummies(df.neighbourhood_cleansed)
df_neigh
```

[39]:	Alaró	Alcúdia	Algaida	Andratx	Ariany	Artà	Banyalbufar	\
0	0	0	0	0	0	0	0	
1	0	0	0	0	0	0	0	
2	0	0	0	0	0	0	0	

3 4	0	0	0 0	0 0 0	0		0		
4		···					U		
 17603	0	0	0	0 0			0		
17604	0	0	0	0 0	0		0		
17605	0	0	0	0 0	0		0		
17606	0	0	0	1 0	0		0		
17607	0	0	0	0 0	0		0		
,,	-	-	•				-		
	Binissalem	Bunyola	Búger …	Santa Marí	a del	Camí	Santanyí	Selva	\
0	0	0	0			0	0	0	
1	0	0	0			0	0	0	
2	0	0	0			0	0	0	
3	0	0	0			0	0	0	
4	0	0	0			0	0	0	
	•••		•••	••		•••	***		
17603	0	0	0			0	0	0	
17604	0	0	0			0	0	0	
17605	0	0	0			0	0	1	
17606	0	0	0			0	0	0	
17607	0	0	0			0	0	0	
	Sencelles	Ses Salin	es Sineu	Son Server	a Sól	ler	Valldemoss	a \	
0	0		0 0		0	0		0	
			0		•			•	
1	0		0 0		0	0		0	
1	0		0 0		0	0		0	
1 2	0 0		0 0 0 0		0	0 0		0 0	
1 2 3	0 0 0	,	0 0 0 0 0 0		0 0 0	0 0 0		0 0 0	
1 2 3 4 17603	0 0 0 0	 .	0 0 0 0 0 0 0 0		0 0 0	0 0 0		0 0 0	
1 2 3 4 17603 17604	0 0 0 0		0 0 0 0 0 0 0 0		0 0 0 0	0 0 0 0		0 0 0 0	
1 2 3 4 17603 17604 17605	0 0 0 0	 .	0 0 0 0 0 0 0 0		0 0 0 0	0 0 0 0 		0 0 0 0	
1 2 3 4 17603 17604 17605 17606	0 0 0 0 	 .	0 0 0 0 0 0 0 0 		0 0 0 0 0	0 0 0 0 0		0 0 0 0 0 0 0	
1 2 3 4 17603 17604 17605	0 0 0 0 		0 0 0 0 0 0 0 0 		0 0 0 0 0	0 0 0 0 0		0 0 0 0 0	
1 2 3 4 17603 17604 17605 17606	0 0 0 0 		0 0 0 0 0 0 0 0 		0 0 0 0 0	0 0 0 0 0		0 0 0 0 0 0 0	
1 2 3 4 17603 17604 17605 17606	0 0 0 0 0 0 0		0 0 0 0 0 0 0 0 		0 0 0 0 0	0 0 0 0 0		0 0 0 0 0 0 0	
1 2 3 4 17603 17604 17605 17606 17607	0 0 0 0 0 0 0	le Bonany	0 0 0 0 0 0 0 0 		0 0 0 0 0	0 0 0 0 0		0 0 0 0 0 0 0	
1 2 3 4 17603 17604 17605 17606 17607	0 0 0 0 0 0 0	le Bonany O	0 0 0 0 0 0 0 0 		0 0 0 0 0	0 0 0 0 0		0 0 0 0 0 0 0	
1 2 3 4 17603 17604 17605 17606 17607	0 0 0 0 0 0 0	le Bonany O O	0 0 0 0 0 0 0 0 		0 0 0 0 0	0 0 0 0 0		0 0 0 0 0 0 0	
1 2 3 4 17603 17604 17605 17606 17607	0 0 0 0 0 0 0	de Bonany O O	0 0 0 0 0 0 0 0 		0 0 0 0 0	0 0 0 0 0		0 0 0 0 0 0 0	
1 2 3 4 17603 17604 17605 17606 17607	0 0 0 0 0 0 0	le Bonany 0 0 0	0 0 0 0 0 0 0 0 		0 0 0 0 0	0 0 0 0 0		0 0 0 0 0 0 0	
1 2 3 4 17603 17604 17605 17606 17607	0 0 0 0 0 0 0	de Bonany 0 0 0 0	0 0 0 0 0 0 0 0 		0 0 0 0 0	0 0 0 0 0		0 0 0 0 0 0 0	
1 2 3 4 17603 17604 17605 17606 17607	0 0 0 0 0 0 0	de Bonany 0 0 0 0 0	0 0 0 0 0 0 0 0 		0 0 0 0 0	0 0 0 0 0		0 0 0 0 0 0 0	
1 2 3 4 17603 17604 17605 17606 17607 0 1 2 3 4 17603 17604	0 0 0 0 0 0 0	de Bonany	0 0 0 0 0 0 0 0 		0 0 0 0 0	0 0 0 0 0		0 0 0 0 0 0 0	
1 2 3 4 17603 17604 17605 17606 17607 0 1 2 3 4 17603 17604 17605	0 0 0 0 0 0 0	de Bonany 0 0 0 0 0 0	0 0 0 0 0 0 0 0 		0 0 0 0 0	0 0 0 0 0		0 0 0 0 0 0 0	
1 2 3 4 17603 17604 17605 17606 17607 0 1 2 3 4 17603 17604	0 0 0 0 0 0 0	de Bonany	0 0 0 0 0 0 0 0 		0 0 0 0 0	0 0 0 0 0		0 0 0 0 0 0 0	

[17603 rows x 53 columns]

```
[40]: df = df.drop(columns = ['neighbourhood_cleansed'])
      df = pd.concat([df, df_neigh], axis=1)
      df.head()
[40]:
                    host_is_superhost
                                        host_identity_verified
                                                                  latitude
                                                                             longitude
                                                                               2.48182
      0
          11547.0
                                   0.0
                                                                  39.51888
                                                             1.0
      1
         100831.0
                                   0.0
                                                             1.0
                                                                  39.76347
                                                                               3.16255
      2
                                   1.0
         105891.0
                                                             1.0
                                                                  39.66044
                                                                               3.07165
      3 106833.0
                                   0.0
                                                             1.0
                                                                  39.61600
                                                                               3.30121
                                                                  39.56478
      4 130669.0
                                   0.0
                                                             0.0
                                                                               2.60333
         accommodates bedrooms
                                   beds
                                         price
                                                 minimum nights
      0
                   2.0
                              1.0
                                    1.0
                                          89.0
                                                             5.0
                   8.0
                              4.0
                                                             7.0
      1
                                    7.0
                                         175.0
      2
                   6.0
                              3.0
                                    4.0
                                         140.0
                                                             6.0
      3
                   4.0
                              2.0
                                         200.0
                                                             5.0
                                    4.0
                   2.0
                                                             2.0
                              1.0
                                    2.0 110.0
         Santa María del Camí
                                Santanyí Selva
                                                   Sencelles
                                                               Ses Salines
      0
                              0
                                        0
                                                0
                                                            0
                                                                          0
                                                                                 0
                              0
                                         0
                                                0
                                                            0
                                                                          0
                                                                                 0
      1
      2
                                                                          0
                              0
                                         0
                                                0
                                                            0
                                                                                 0
      3
                              0
                                                0
                                                            0
                                                                                 0
                                         0
                                                                          0
      4
                              0
                                         0
                                                0
                                                            0
                                                                                 0
         Son Servera
                       Sóller
                               Valldemossa
                                             Vilafranc de Bonany
      0
                    0
                             0
      1
                    0
                             0
                                           0
                                                                 0
      2
                    0
                                           0
                                                                 0
                             0
      3
                    0
                             0
                                           0
                                                                 0
                             0
                                           0
                                                                 0
```

[5 rows x 208 columns]

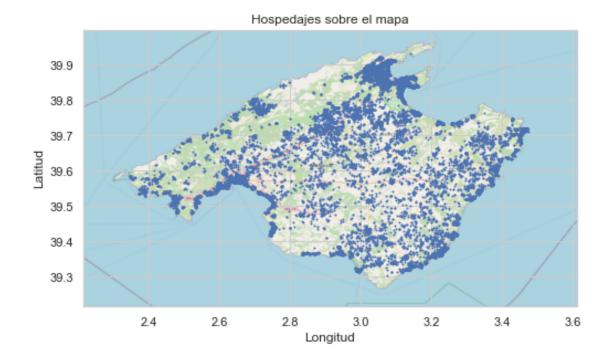
2.5 Columnas de latitud y longitud

El siguiente paso es ver si la ubicación precisa de los hospedajes tiene algún tipo de colinearidad con el precio. Para empezar vamos a ver la distribución de los alojamientos sobre la isla:

```
[41]: box = ((2.2165, 3.6118, 39.2152, 39.9982)) #lonmin, lonmax, latmin, latmax maping = plt.imread(path_img_map)
fig, ax = plt.subplots(figsize = (8,7))
```

```
ax.scatter(df.longitude, df.latitude, zorder=1, c='b', s=1)
ax.set_title('Hospedajes sobre el mapa')
ax.set_xlabel('Longitud')
ax.set_xlim(box[0],box[1])
ax.set_ylabel('Latitud')
ax.set_ylim(box[2],box[3])
ax.imshow(mapimg, zorder=0, extent = box, aspect= 'equal')
```

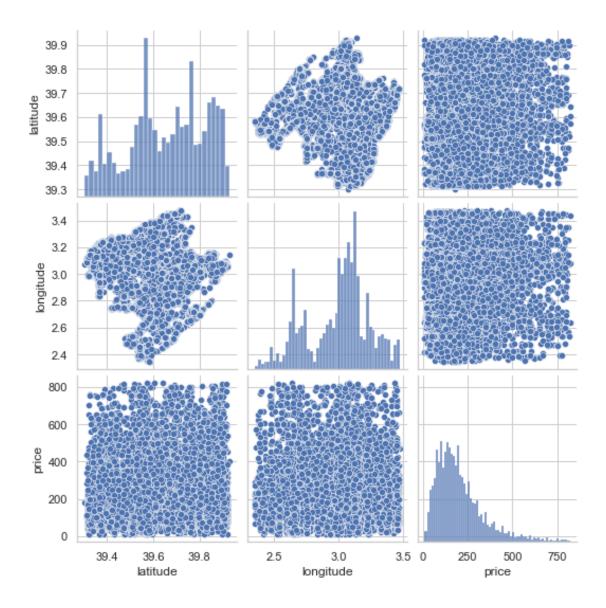
[41]: <matplotlib.image.AxesImage at 0x7fb780adc450>



Vista la distribución general de los hospedajes en la isla, aunque hay algunos núcleos, no se puede decir que la distribución a lo largo de los ejes de latitud y longitud sea relevante. A diferencia de las concentraciones en algunas zonas, que probablemente se vean representadas por la agrupación por vecindarios mejor que por estas dos variables. Aún así veamos si hay algún tipo de relación entre ellas y el precio con un *pairplot*;

```
[42]: sns.pairplot(df[['latitude', 'longitude','price']])
```

[42]: <seaborn.axisgrid.PairGrid at 0x7fb780a2dc50>



Como decíamos no se ve ninguna relación. Tampoco con el *pairplot*. Podemos decir que las columnas de latitud y longitud no tienen relevancia para el estudio, por tanto, las eliminamos.

Estudio final de valores nulos A continuación se presenta la información sobre el dataset ya modificado:

```
[44]: df.info()
```

<class 'pandas.core.frame.DataFrame'>
Int64Index: 17603 entries, 0 to 17607

Columns: 206 entries, id to Vilafranc de Bonany

dtypes: float64(148), object(1), uint8(57)

memory usage: 21.6+ MB

Convertimos las variables al tipo más óptimo utilizando una función de la librería pandas: con $vert_dtypes.$

	oci v_wigpeo.										
[45]:	df.con	vert_dtype	s()								
[45]:		id	host_	is_supe	rhost	host_ide	entity	_verified	accomm	odates	\
	0	11547			0			1		2	
	1	100831			0			1		8	
	2	105891			1			1		6	
	3	106833			0			1		4	
	4	130669			0			0		2	
	•••	•••		•••				•••	•••		
	17603	45489412			0			1		6	
	17604	45489550			0			1		9	
	17605	45493152			0			1		6	
	17606	45496032			0			0		2	
	17607	45499210			0			0		6	
		, ,	, ,						,		
	0	bedrooms	beds	price	minim	_		imum_night			
	0	1	1	89.0		5		6			
	1	4	7	175.0		7		36			
	2	3	4	140.0		6		36			
	3	2	4	200.0		5		36			
	4	1	2	110.0		2	2	36	5		
	 17603	 o		10E 0	•••	1	•••	26	_		
		3	4	195.0		1		36			
	17604	5	8	110.0		1		112			
	17605	3	4	179.0		1		36			
	17606	1	1	42.0		1		110	7		
	17607	2	4	100.0		5)	112	O		
		has_avail	abilit	y S	Santa M	aría del	Camí	Santanyí	Selva	\	
	0			1			0	0	0		
	1			1			0	0	0		
	2			1			0	0	0		
	3			1			0	0	0		
	4			1			0	0	0		
	•••					•••					
	17603			1			0	0	0		
	17604			1			0	0	0		
	17605			1			0	0	1		
	17606			1			0	0	0		
	17607			1			0	0	0		

Sencelles Ses Salines Sineu Son Servera Sóller Valldemossa \setminus

0	0	0	0	0	0	0
1	0	0	0	0	0	0
2	0	0	0	0	0	0
3	0	0	0	0	0	0
4	0	0	0	0	0	0
•••	•••		•••	•••	•••	
 17603	0		0	0	 0	0
	 0 0		 0 0	 0 0	 0 0	0
17603	 0 0 0		0 0 0	 0 0 0	 0 0 0	0 0 0
17603 17604	 0 0 0		 0 0 0	 0 0 0	 0 0 0	0 0 0 0

Vilafranc de Bonany

[17603 rows x 206 columns]

Ahora que ya se ha visto la forma del dataset, falta hacer un último análisis de valores nulos.

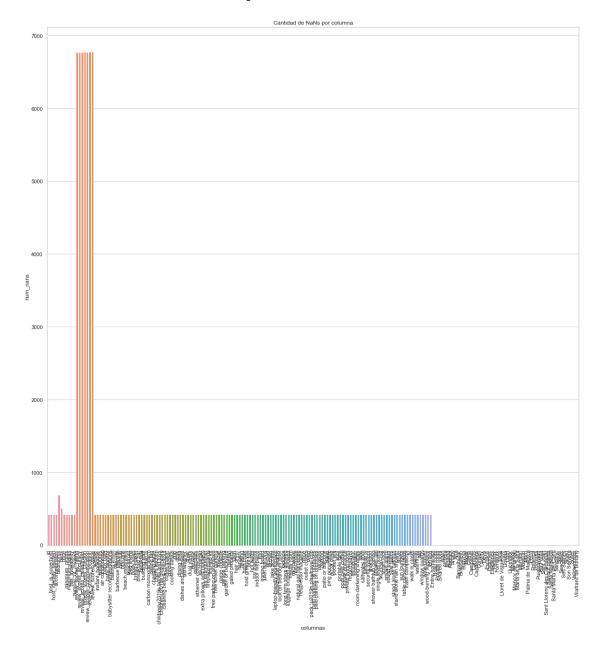
```
[46]: nan_df = pd.DataFrame(df.isna().sum())
nan_df.reset_index(level = 0, inplace= True)
nan_df.columns = ['columnas', 'num_nans']
nan_df
```

```
[46]:
                           columnas num_nans
      0
                                           422
                                 id
                                           424
      1
                 host_is_superhost
      2
           host_identity_verified
                                           424
      3
                                           422
                      accommodates
      4
                                           692
                           bedrooms
      . .
      201
                              Sineu
                                             0
      202
                        Son Servera
                                             0
      203
                                             0
                             Sóller
      204
                        Valldemossa
                                             0
      205
                                             0
               Vilafranc de Bonany
```

[206 rows x 2 columns]

```
[47]: fig, ax = plt.subplots(figsize=(20, 20))
ax = sns.barplot(x = nan_df.columnas, y= nan_df.num_nans, data=nan_df)
ax.set_xticklabels(ax.get_xticklabels(),rotation=90)
ax.set_title('Cantidad de NaNs por columna')
```

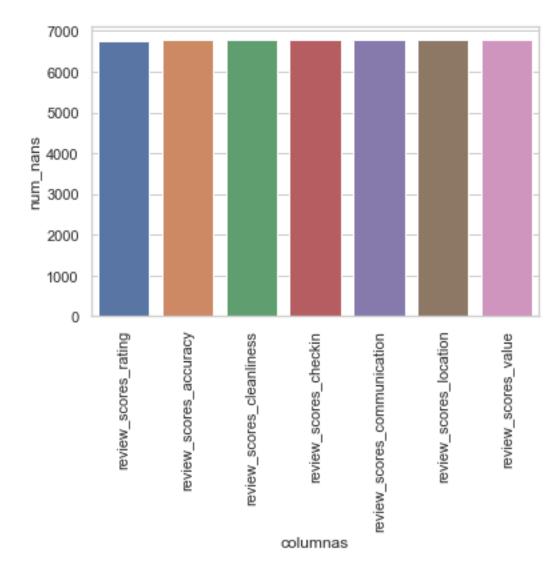
[47]: Text(0.5, 1.0, 'Cantidad de NaNs por columna')



Teniendo en cuenta la longitud del dataset, se puede identificar una serie de columnas que tienen

gran cantidad de nans y que, por tanto no aportan información. Se identifican a continuación utilizando un plot reducido:

```
[48]: fig, ax = plt.subplots()
aux = nan_df.loc[nan_df.num_nans > 1000,:]
ax = sns.barplot(x = aux.columnas, y= aux.num_nans, data=aux)
ax.set_xticklabels(ax.get_xticklabels(),rotation=90)
```



```
[49]: aux.num_nans.max() / len(df) * 100
```

[49]: 38.493438618417315

Eliminar las filas con NaNs del dataset significaría perder un 40% de los datos. La mejor manera de realizar esta operación es eliminar las columnas, que aportan poca información al análisis.

```
[50]: columnas_a_borrar = nan_df.loc[nan_df.num_nans > 1000,:].columnas.tolist()
df = df.drop(columns = columnas_a_borrar)
df.head()
```

[50]:		id	host	_is_super	host	host	_ident	tity_	verified	ac	commodate	s \		
	0	11547.0		-	0.0			• -	1.0		2.0)		
	1	100831.0			0.0				1.0		8.0)		
	2	105891.0			1.0				1.0		6.0)		
	3	106833.0			0.0				1.0		4.0)		
	4	130669.0			0.0				0.0		2.0)		
		bedrooms	beds	price	minim	um_ni	ghts	maxi	num_night	ts :	has_availa	abili	ty	\
	0	1.0	1.0	89.0			5.0		60	. 0		1	1.0	
	1	4.0	7.0	175.0			7.0		365	. 0		1	.0	
	2	3.0	4.0	140.0			6.0		365	. 0		1	1.0	
	3	2.0	4.0	200.0			5.0		365	. 0		1	1.0	
	4	1.0	2.0	110.0			2.0		365	. 0		1	.0	
		Santa	María	del Camí	Santa	anyí	Selva	a Sei	ncelles	Ses	Salines	Sine	eu	\
	0			0		0	(0		0		0	
	1	•••		0)	0	()	0		0		0	
	2	•••		0)	0	()	0		0		0	
	3	•••		0)	0	()	0		0		0	
	4	•••		0)	0	()	0		0		0	

Son Servera	Sóller	Valldemossa	Vilafranc de Bonany
0	0	0	0
0	0	0	0
0	0	0	0
0	0	0	0
0	0	0	0
	Son Servera 0 0 0 0 0 0	Son Servera Sóller 0 0 0 0 0 0 0 0 0 0 0 0	Son Servera Sóller Valldemossa 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0

[5 rows x 199 columns]

Ahora podemos borrar las filas con nans, que parecen coincidir en muchas de las columnas originales del dataset y que no son una cantidad de datos significativa con respecto al dataset.

```
[51]: df.dropna()
```

```
[51]:
                       id host_is_superhost host_identity_verified accommodates \
                 11547.0
                                                                                    2.0
      0
                                          0.0
                                                                     1.0
                                          0.0
                                                                                    8.0
      1
                100831.0
                                                                     1.0
      2
                105891.0
                                          1.0
                                                                     1.0
                                                                                    6.0
      3
                106833.0
                                          0.0
                                                                     1.0
                                                                                    4.0
      4
                130669.0
                                          0.0
                                                                     0.0
                                                                                    2.0
                                                                                    2.0
      17175
              44663146.0
                                          0.0
                                                                     1.0
             44664664.0
                                          0.0
                                                                     1.0
                                                                                    1.0
      17176
                                          0.0
      17177
              44672575.0
                                                                     1.0
                                                                                    4.0
      17179
              44673578.0
                                          0.0
                                                                     1.0
                                                                                    8.0
      17180
             44673714.0
                                          0.0
                                                                     1.0
                                                                                    6.0
              bedrooms
                         beds
                              price
                                       minimum_nights
                                                        maximum_nights
      0
                          1.0
                                89.0
                                                   5.0
                                                                    60.0
                   1.0
                   4.0
                                                   7.0
                                                                   365.0
      1
                          7.0
                               175.0
      2
                   3.0
                          4.0
                               140.0
                                                   6.0
                                                                   365.0
      3
                   2.0
                          4.0
                               200.0
                                                   5.0
                                                                   365.0
      4
                   1.0
                          2.0
                               110.0
                                                   2.0
                                                                   365.0
                          0.0
                                                                  1125.0
      17175
                   1.0
                                88.0
                                                   1.0
                   2.0
                          4.0
                                40.0
                                                   1.0
                                                                   365.0
      17176
      17177
                   2.0
                          2.0
                               120.0
                                                   5.0
                                                                    14.0
      17179
                   4.0
                          4.0
                               548.0
                                                   1.0
                                                                   365.0
      17180
                   3.0
                          3.0 180.0
                                                   5.0
                                                                    14.0
                                     Santa María del Camí Santanyí Selva
              has_availability ...
                                                                              Sencelles
      0
                            1.0
                                                          0
                                                                    0
                                                                            0
                                                                                        0
                                                          0
                                                                    0
      1
                            1.0
                                                                            0
                                                                                        0
      2
                            1.0
                                                          0
                                                                    0
                                                                            0
                                                                                        0
      3
                                                                    0
                            1.0
                                                          0
                                                                            0
                                                                                        0
      4
                            1.0
                                                          0
                                                                    0
                                                                            0
                                                                                        0
      17175
                            1.0
                                                          0
                                                                    0
                                                                            0
                                                                                        0
      17176
                            1.0
                                                          0
                                                                    0
                                                                            0
                                                                                        0
                                                                    0
                                                                            0
      17177
                            1.0
                                                          0
                                                                                        0
      17179
                            1.0
                                                          0
                                                                    0
                                                                            0
                                                                                        1
      17180
                            1.0
                                                                    0
                                                          Valldemossa
              Ses Salines
                            Sineu
                                    Son Servera
                                                  Sóller
      0
                         0
                                0
                                                        0
                                               0
                         0
                                0
                                               0
                                                        0
                                                                      0
      1
      2
                         0
                                 0
                                               0
                                                        0
                                                                      0
      3
                                                        0
                                                                      0
                         0
                                 0
                                               0
                                               0
                                                        0
                                                                      0
                         0
                                 0
      17175
                         0
                                0
                                               0
                                                                      0
```

17176	0	0	0	0	0
17177	0	0	0	0	0
17179	0	0	0	0	0
17180	0	0	0	0	0

Vilafranc de Bonany 0 1 0 2 0 3 0 4 0 17175 0 17176 0 17177 0 0 17179 17180 0

[16419 rows x 199 columns]

Para poder analizar la influencia del preprocesado en el dataset, se vuelven a realizar las comprobaciones iniciales de distribución y de outliers.

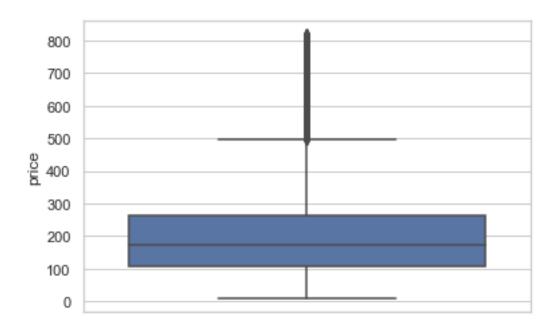
En primer lugar analizamos la estadística del precio:

```
[52]: df.price.describe()
```

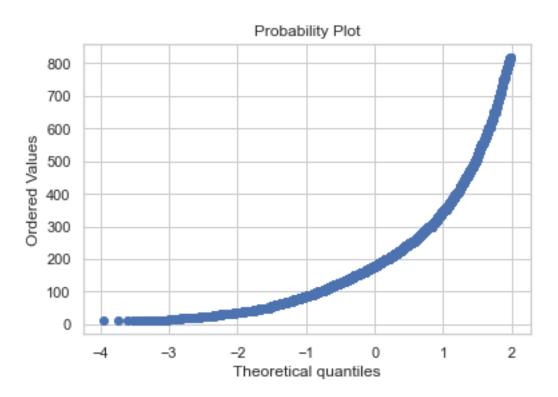
```
[52]: count
                17181.000000
                  207.043386
      mean
                  139.862822
      std
      min
                   10.000000
      25%
                  109.000000
      50%
                  175.000000
      75%
                  264.000000
                  819.000000
      max
```

Name: price, dtype: float64

```
[53]: sns.set_theme(style="whitegrid") ax = sns.boxplot(y="price", data=df)
```

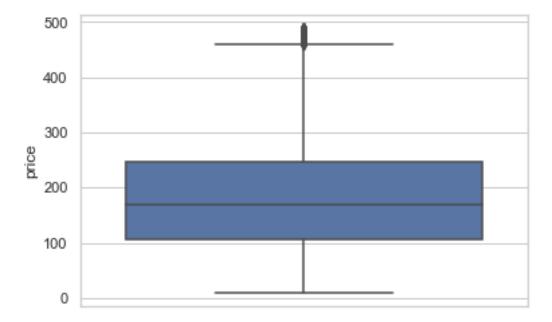


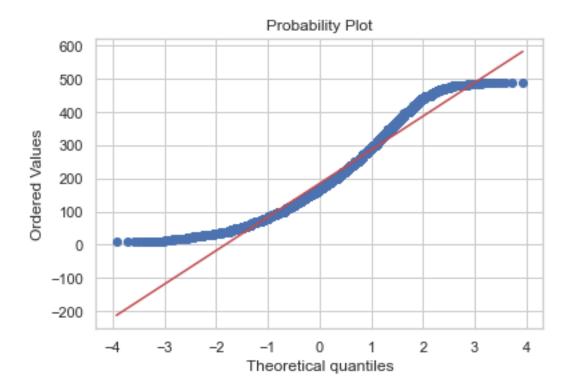
```
[54]: stats.probplot(df.price, plot=sns.mpl.pyplot)
```



La distribución de precios continua en la misma línea, se pueden apreciar cambios poco significativos, como por ejemplo un descenso de la media (de 244 a 207). De ello se deduce que a pesar del tratamiento, el dataset conserva la estructura inicial, no así la estructura con respecto a la distribución por quantiles, lo que hace necesario un recorte mayor de *outliers*. En este caso nos quedamos únicamente con los datos

```
[55]: std = df.price.describe()[2]
dfB = df.loc[(df.price <= 3.5*std )]
sns.set_theme(style="whitegrid")
ax = sns.boxplot(y="price", data=dfB)</pre>
```





Filtrando por más del 99% de los datos (tres veces y media la desviación estándar) conseguimos limitar el efecto de *outliers* y el ajuste a cuantiles teóricos en la distribución por quantiles.

2.6 Escalado de datos: train y test

Ya por último se escalan los datos. Para este proceso separaremos en dos *datasets* uno para el entrenamiento y otro para el test. Haremos un entrenamiento de un modelo de escalado, propio de la librería sklearn y lo aplicaremos a ambos.

En primer lugar haremos la separación entre los conjuntos de entrenamiento y test:

```
[64]: df_train, df_test = train_test_split(dfB, test_size= 0.33)
```

```
-> 5460
                           return object.__getattribute__(self, name)
          5461
                   def __setattr__(self, name: str, value) -> None:
          5462
       AttributeError: 'DataFrame' object has no attribute 'asDataFrame'
     A continuación comprobamos que el análisis estadístico de ambos es similar.
[58]: df_train.price.describe()
[58]: count
               10919.000000
      mean
                 184.815242
      std
                 103.773949
                  10.000000
      min
      25%
                 104.000000
      50%
                 167.000000
      75%
                 247.000000
                 489.000000
      max
      Name: price, dtype: float64
[59]: df_test.price.describe()
[59]: count
               5379.000000
      mean
                185.518883
      std
                103.711458
      min
                 10.000000
      25%
                105.500000
      50%
                169.000000
      75%
                248.000000
      max
                489.000000
      Name: price, dtype: float64
     Una vez realizada esta comprobación, vamos se escalan los datos:
[61]: funcion_escalado = StandardScaler().fit(df_train) #entrenamiento con el dataset_
       \rightarrow de entrenamiento
      df_train = funcion_escalado.transform(df_train)
      df_test = funcion_escalado.transform(df_test)
[66]: df_train = pd.DataFrame(df_train, index=df_train.index, columns=df_train.
       df_train.describe().price
               10919.000000
[66]: count
      mean
                 184.517802
```

std

103.375700

```
min 10.000000
25% 105.000000
50% 167.000000
75% 246.000000
max 489.000000
Name: price, dtype: float64
```

```
[68]: df_test = pd.DataFrame(df_test, index=df_test.index, columns=df_test.columns)
df_test.describe().price
```

```
[68]: count
               5379.000000
      mean
                186.122666
                104.509099
      std
                 10.000000
      min
      25%
                104.000000
      50%
                169.000000
      75%
                250.000000
      max
                489.000000
```

Name: price, dtype: float64

Con este último tratamiento se cierra el preprocesado y podemos pasar a la selección, entrenamiento y validación del modelo.

3 Modelización

En este apartado utilizaremos los conjuntos ya procesados para la selección del modelo y su entrenamiento. EL modelo seleccionado es un modelo de regresión. Se empezará por