Práctica Final AA

February 17, 2021

Autora: Helena Antich Homar

Asignatura: Aprendizaje automático
Ejercicio: Práctica final: *Dataset* de Airbnb
Fecha de entrega: 17 Febrero de 2021
Enlace a repositorio abierto: Proyecto Airbnb de HelenaAH30

Descripción del programa: Este programa analiza y limpia los datos del fichero de Airbnb

1 Librerías y directorios

A continuación vamos a cargar todas las librerías a utilizar en el programa y a determinar el directorio de trabajo para poder leer los datos.
Para modificar el directorio de trabajo, en el que se ubica el fichero de datos y una imagen auxiliar (adjuntada), hay que modificar la variable `working_directory`.

[1]:
```
#%% Libraries
import os
import numpy as np
import pandas as pd
import seaborn as sns
from scipy import stats
import matplotlib.pyplot as plt
from sklearn.feature_extraction.text import CountVectorizer
from sklearn.preprocessing import StandardScaler
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression, Ridge, TweedieRegressor,␣
↪SGDRegressor
from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score
#from sklearn.cross_validation import cross_val_score
```

[2]:
```
#%% Directories
working_directory = '/Users/Helena/Documents/MASTER MUSI/AA - ML - Aprendizaje␣
↪automático/FINAL' #cambiar para poder realizar el cargado de los datos y la␣
↪imagen auxiliar
```

```
os.chdir(working_directory)
path_data = os.path.join(os.getcwd(), 'airbnb.csv') # datos utilizados para el␣
 ↪entrenamiento del modelo
path_img_map = os.path.join(os.getcwd(), 'map.png') # mapa para la␣
 ↪representación de los datos sobre la isla de Mallorca
```

2 Preprocesado de los datos

En este apartado trataremos los datos para optimizar el entrenamiento de la IA que se realizará al final.

A continuación cargamos los datos y vemos una breve descripción:

[3]:
```
#%% Loading data
df_airbnb_raw = pd.read_csv(path_data)
df_airbnb = df_airbnb_raw.copy()
#df_airbnb.head()
df_airbnb.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 17608 entries, 0 to 17607
Data columns (total 74 columns):
 #   Column                                        Non-Null Count  Dtype
---  ------                                        --------------  -----
 0   id                                            17608 non-null  int64
 1   listing_url                                   17608 non-null  object
 2   scrape_id                                     17608 non-null  int64
 3   last_scraped                                  17608 non-null  object
 4   name                                          17607 non-null  object
 5   description                                   17393 non-null  object
 6   neighborhood_overview                         8213 non-null   object
 7   picture_url                                   17608 non-null  object
 8   host_id                                       17608 non-null  int64
 9   host_url                                      17608 non-null  object
 10  host_name                                     17606 non-null  object
 11  host_since                                    17606 non-null  object
 12  host_location                                 17572 non-null  object
 13  host_about                                    11696 non-null  object
 14  host_response_time                            15862 non-null  object
 15  host_response_rate                            15862 non-null  object
 16  host_acceptance_rate                          16098 non-null  object
 17  host_is_superhost                             17606 non-null  object
 18  host_thumbnail_url                            17606 non-null  object
 19  host_picture_url                              17606 non-null  object
 20  host_neighbourhood                            364 non-null    object
```

```
21  host_listings_count                    17606 non-null  float64
22  host_total_listings_count              17606 non-null  float64
23  host_verifications                     17608 non-null  object
24  host_has_profile_pic                   17606 non-null  object
25  host_identity_verified                 17606 non-null  object
26  neighbourhood                          8213 non-null   object
27  neighbourhood_cleansed                 17608 non-null  object
28  neighbourhood_group_cleansed           0 non-null      float64
29  latitude                               17608 non-null  float64
30  longitude                              17608 non-null  float64
31  property_type                          17608 non-null  object
32  room_type                              17608 non-null  object
33  accommodates                           17608 non-null  int64
34  bathrooms                              0 non-null      float64
35  bathrooms_text                         17600 non-null  object
36  bedrooms                               17333 non-null  float64
37  beds                                   17511 non-null  float64
38  amenities                              17608 non-null  object
39  price                                  17608 non-null  object
40  minimum_nights                         17608 non-null  int64
41  maximum_nights                         17608 non-null  int64
42  minimum_minimum_nights                 17608 non-null  int64
43  maximum_minimum_nights                 17608 non-null  int64
44  minimum_maximum_nights                 17608 non-null  int64
45  maximum_maximum_nights                 17608 non-null  int64
46  minimum_nights_avg_ntm                 17608 non-null  float64
47  maximum_nights_avg_ntm                 17608 non-null  float64
48  calendar_updated                       0 non-null      float64
49  has_availability                       17608 non-null  object
50  availability_30                        17608 non-null  int64
51  availability_60                        17608 non-null  int64
52  availability_90                        17608 non-null  int64
53  availability_365                       17608 non-null  int64
54  calendar_last_scraped                  17608 non-null  object
55  number_of_reviews                      17608 non-null  int64
56  number_of_reviews_ltm                  17608 non-null  int64
57  number_of_reviews_l30d                 17608 non-null  int64
58  first_review                           11173 non-null  object
59  last_review                            11173 non-null  object
60  review_scores_rating                   10957 non-null  float64
61  review_scores_accuracy                 10951 non-null  float64
62  review_scores_cleanliness              10953 non-null  float64
63  review_scores_checkin                  10949 non-null  float64
64  review_scores_communication            10951 non-null  float64
65  review_scores_location                 10950 non-null  float64
66  review_scores_value                    10949 non-null  float64
67  license                                11431 non-null  object
68  instant_bookable                       17608 non-null  object
```

```
 69  calculated_host_listings_count                 17608 non-null  int64
 70  calculated_host_listings_count_entire_homes    17608 non-null  int64
 71  calculated_host_listings_count_private_rooms   17608 non-null  int64
 72  calculated_host_listings_count_shared_rooms    17608 non-null  int64
 73  reviews_per_month                              11173 non-null  float64
dtypes: float64(19), int64(21), object(34)
memory usage: 9.9+ MB
```

2.1 Eliminación de columnas nulas

Viendo que hay columnas que son todo "null" podemos eliminarlas directamente, ya que no aportan información.

[4]:
```
df_airbnb = df_airbnb.drop(columns =␣
 ↪['calendar_updated','bathrooms','neighbourhood_group_cleansed'])
df_airbnb.head()
```

[4]:

	id	listing_url	scrape_id	last_scraped	name	description	neighborhood_overview	picture_url	host_id
0	11547	https://www.airbnb.com/rooms/11547	20200919153121	2020-09-21	My home at the beach	Sun, joy, relax, quality, beach & peace. …	NaN	https://a0.muscache.com/pictures/494126/8c151b…	42942
1	100831	https://www.airbnb.com/rooms/100831	20200919153121	2020-09-21	HOUSE IN MALLORCA - WiFi(ET-3045)	The space House situated in a quie…	NaN		
2	105891	https://www.airbnb.com/rooms/105891	20200919153121	2020-09-20	VILLAGE HOUSE WITH POOL: IDEAL FOR FAMILIES	The house is a street on the outskirts of the …	The village's population does not reach two th…		
3	106833	https://www.airbnb.com/rooms/106833	20200919153121	2020-09-20	Villa with a big pool in Mallorca	The space This is a restored old b…	NaN		
4	130669	https://www.airbnb.com/rooms/130669	20200919153121	2020-09-20	Room great apartment	Located in a residential neighbourhood and 10m…	Located in the center of the city, within minu…		

```
1  https://a0.muscache.com/pictures/675527/72b329…   529151
2  https://a0.muscache.com/pictures/1036816/f36ce…   549192
3  https://a0.muscache.com/pictures/710218/98134c…   551974
4  https://a0.muscache.com/pictures/866653/58dc48…   643065

                                host_url  … review_scores_communication  \
0   https://www.airbnb.com/users/show/42942  …                         10.0
1  https://www.airbnb.com/users/show/529151  …                         10.0
2  https://www.airbnb.com/users/show/549192  …                         10.0
3  https://www.airbnb.com/users/show/551974  …                         10.0
4  https://www.airbnb.com/users/show/643065  …                          NaN

  review_scores_location review_scores_value   license instant_bookable  \
0                   10.0                10.0       NaN                 f
1                   10.0                10.0  ETV-3045                 t
2                    9.0                10.0  ETV/6127                 t
3                    9.0                 9.0   ET/1961                 f
4                    NaN                 NaN       NaN                 t

  calculated_host_listings_count calculated_host_listings_count_entire_homes  \
0                              1                                             1
1                              1                                             1
2                              2                                             2
3                              1                                             1
4                              2                                             0

  calculated_host_listings_count_private_rooms  \
0                                            0
1                                            0
2                                            0
3                                            0
4                                            2

  calculated_host_listings_count_shared_rooms reviews_per_month
0                                           0              0.93
1                                           0              1.47
2                                           0              0.14
3                                           0              0.09
4                                           0               NaN

[5 rows x 71 columns]
```

2.2 Tratamiento de la columna precio

Además el precio, que es la variable a predecir, es de tipo "objeto" y debería ser de tipo valor, incluso para hace el estudio de outliers.

[5]:
```
df_airbnb.price = df_airbnb.price.str.replace("$","").str.replace(",","").
 ↪astype(float)
df_airbnb.price.dtype
df_airbnb.price.head()
```

[5]:
```
0     89.0
1    175.0
2    140.0
3    200.0
4    110.0
Name: price, dtype: float64
```

Ahora que el precio es del tipo número de coma flotante, veamos un resumen estadístico de esta columna:

[6]:
```
df_airbnb.price.describe()
```

[6]:
```
count    17608.000000
mean       244.383561
std        409.958169
min          0.000000
25%        110.000000
50%        179.000000
75%        275.000000
max      20736.000000
Name: price, dtype: float64
```

Dado que el mínimo es un "0" absoluto, tiene que haber un valor al menos que no tenga ningún precio. Este objeto sin precio puede desplazar la media y complicar el análisis mientras que en la realidad no aporta información. Por ello lo eliminamos.

[7]:
```
df_airbnb[df_airbnb.price == 0.]
df_airbnb = df_airbnb[df_airbnb.price != 0.]
df_airbnb.price.describe()
```

[7]:
```
count    17607.000000
mean       244.397441
std        409.965674
min         10.000000
25%        110.000000
50%        179.000000
75%        275.000000
max      20736.000000
Name: price, dtype: float64
```

2.3 Análisis y eliminación de outliers

Teniendo en cuenta la desviación estándar, vamos a filtrar el dataframe para eliminar outliers analizando la distribución estadística del precio (boxplot) y la distribución por cuantiles (probplot).

Nota: A lo largo del procesado de las columnas se ha ido realizando este estudio a modo de monitorización del dataset.

[8]:
```
std = df_airbnb.price.describe()[2]
df = df_airbnb.loc[(df_airbnb.price <= 2*std )]
sns.set_theme(style="whitegrid")
ax = sns.boxplot(y="price", data=df)
```

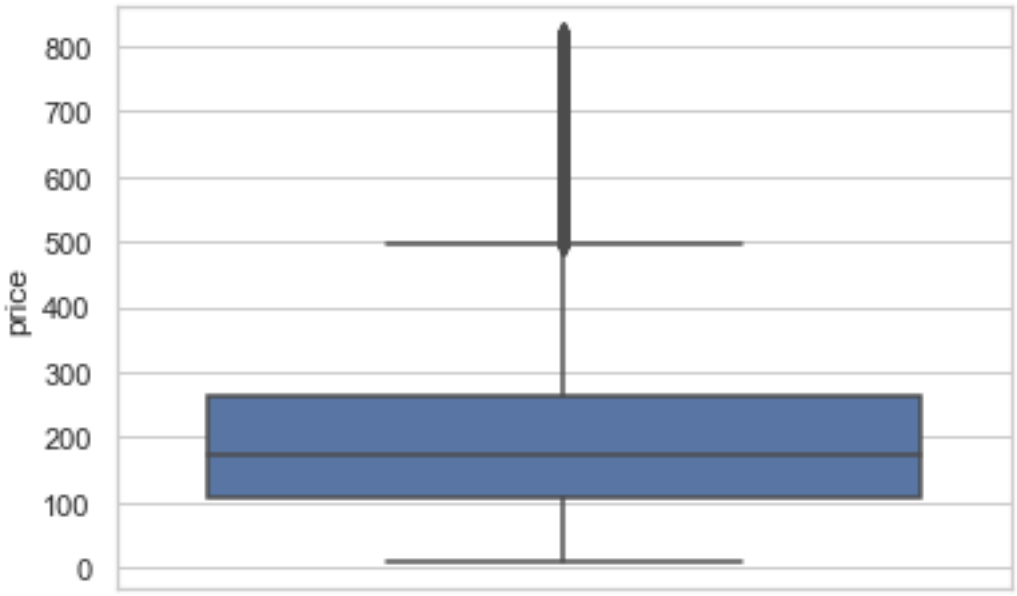

[9]:
```
stats.probplot(df.price, plot=sns.mpl.pyplot)
```

[9]:
```
((array([-3.94235327, -3.72430797, -3.6049135 , …,  3.6049135 ,
          3.72430797,  3.94235327]),
  array([ 10.,  10.,  10., …, 819., 819., 819.])),
 (131.29438762345103, 207.04338629881855, 0.9385583739817922))
```

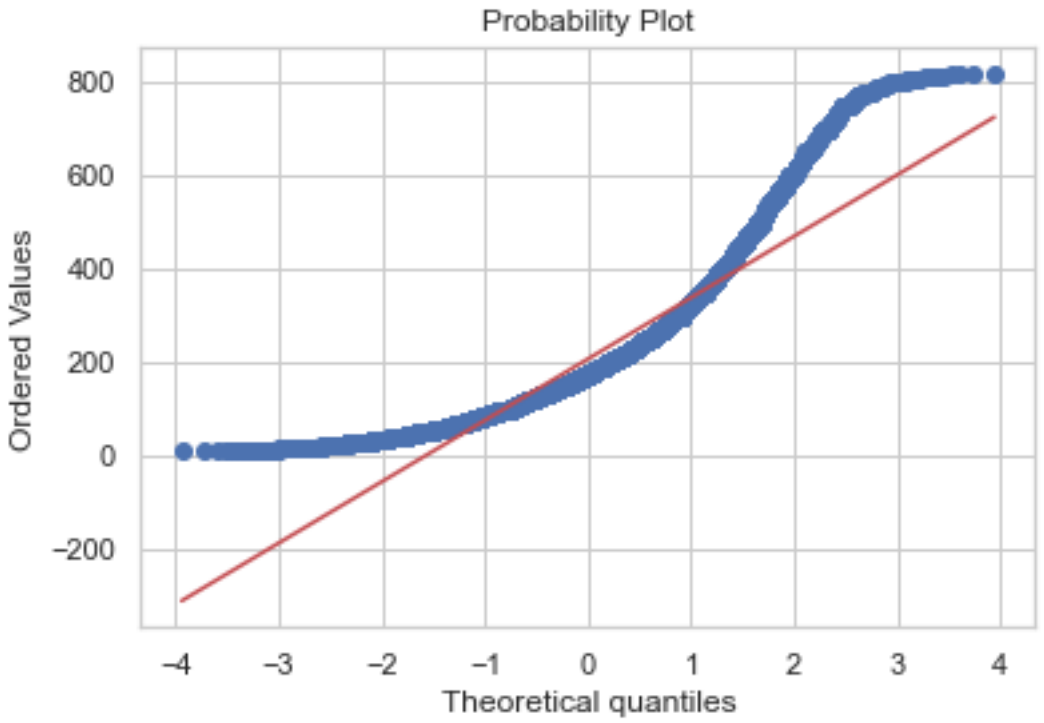

Habiendo analizado las distribuciones nos hemos quedado con el 95,4% de los datos. Lo que equivale a dos veces la desviación estándar. Se conservan algunos outliers para poder precedecir ciertos comportamientos anómalos con el modelo.

2.4 Tratamiento de columnas y variables

A continuación vamos a seguir tratando las columnas del dataset. Para empezar, leyendo las primeras filas del dataset, podemos determinar si es posible utilizar la información que hay en las columnas.

[10]:
```
df.columns
df.head()
```

[10]:
```
        id                            listing_url       scrape_id last_scraped  \
0    11547   https://www.airbnb.com/rooms/11547  20200919153121   2020-09-21
1   100831  https://www.airbnb.com/rooms/100831  20200919153121   2020-09-21
2   105891  https://www.airbnb.com/rooms/105891  20200919153121   2020-09-20
3   106833  https://www.airbnb.com/rooms/106833  20200919153121   2020-09-20
4   130669  https://www.airbnb.com/rooms/130669  20200919153121   2020-09-20

                                        name  \
0                       My home at the beach
1            HOUSE IN MALLORCA - WiFi(ET-3045)
```

```
2  VILLAGE HOUSE WITH POOL: IDEAL FOR FAMILIES
3            Villa with a big pool in Mallorca
4                        Room great apartment

                                        description  \
0  Sun, joy, relax, quality, beach & peace.<br />…
1  <b>The space</b><br />House situated in a quie…
2  The house is a street on the outskirts of the …
3  <b>The space</b><br />This is a restored old b…
4  Located in a residential neighbourhood and 10m…

                               neighborhood_overview  \
0                                                NaN
1                                                NaN
2  The village's population does not reach two th…
3                                                NaN
4  Located in the center of the city, within minu…

                                        picture_url  host_id  \
0  https://a0.muscache.com/pictures/494126/8c151b…    42942
1  https://a0.muscache.com/pictures/675527/72b329…   529151
2  https://a0.muscache.com/pictures/1036816/f36ce…   549192
3  https://a0.muscache.com/pictures/710218/98134c…   551974
4  https://a0.muscache.com/pictures/866653/58dc48…   643065

                                   host_url  … review_scores_communication  \
0   https://www.airbnb.com/users/show/42942  …                         10.0
1  https://www.airbnb.com/users/show/529151  …                         10.0
2  https://www.airbnb.com/users/show/549192  …                         10.0
3  https://www.airbnb.com/users/show/551974  …                         10.0
4  https://www.airbnb.com/users/show/643065  …                          NaN

  review_scores_location review_scores_value   license instant_bookable  \
0                   10.0                10.0       NaN                 f
1                   10.0                10.0  ETV-3045                 t
2                    9.0                10.0  ETV/6127                 t
3                    9.0                 9.0   ET/1961                 f
4                    NaN                 NaN       NaN                 t

  calculated_host_listings_count calculated_host_listings_count_entire_homes  \
0                              1                                             1
1                              1                                             1
2                              2                                             2
3                              1                                             1
4                              2                                             0

  calculated_host_listings_count_private_rooms  \
```

```
0                                                 0
1                                                 0
2                                                 0
3                                                 0
4                                                 2

  calculated_host_listings_count_shared_rooms reviews_per_month
0                                           0              0.93
1                                           0              1.47
2                                           0              0.14
3                                           0              0.09
4                                           0               NaN

[5 rows x 71 columns]
```

Ahora vamos a seleccionar las columnas que creemos que pueden ser relevantes. Algunos de los motivos de descarte pueden ser: * Descartamos las columnas, por ejemplo: `listing_url`, `scrape_id`, `name`, `description` y `neighborhood_overview`, porque la información de estas columnas se podría encontrar en otras. * Se descartan las columnas, por ejemplo: `picture_url`, `host_id`, y `host_url`, por ser valores aeatorios u arbitrarios asignados a cada hospedaje. * Se eliminan las columnas que se refieren de forma exclusiva al dueño del hospedaje, como nombre o su descripción, que no se refieren al hospedaje o influyen de ninguna manera sobre tiempos de respuesta del comprador.

[11]:
```
df = df.drop(columns = [ 'last_scraped', 'host_since',␣
 ↪'host_location','host_name', 'host_about', 'host_thumbnail_url',␣
 ↪'host_picture_url', 'listing_url', 'scrape_id', 'name', 'description',␣
 ↪'neighborhood_overview','picture_url', 'host_id', 'host_url',␣
 ↪'host_response_rate', 'host_acceptance_rate','host_neighbourhood',␣
 ↪'host_listings_count', 'host_total_listings_count', 'host_verifications',␣
 ↪'host_has_profile_pic','host_response_time','availability_30','availability_60',␣
 ↪'availability_90', 'availability_365','minimum_minimum_nights',␣
 ↪'maximum_minimum_nights', 'minimum_maximum_nights',␣
 ↪'maximum_maximum_nights', 'minimum_nights_avg_ntm',␣
 ↪'maximum_nights_avg_ntm','number_of_reviews_ltm','number_of_reviews_l30d',␣
 ↪'first_review', 'last_review','calculated_host_listings_count',␣
 ↪'calculated_host_listings_count_entire_homes','calculated_host_listings_count_private_rooms
 ↪'calculated_host_listings_count_shared_rooms', 'reviews_per_month',␣
 ↪'neighbourhood', 'calendar_last_scraped'])
df.columns
```

[11]:
```
Index(['id', 'host_is_superhost', 'host_identity_verified',
       'neighbourhood_cleansed', 'latitude', 'longitude', 'property_type',
       'room_type', 'accommodates', 'bathrooms_text', 'bedrooms', 'beds',
       'amenities', 'price', 'minimum_nights', 'maximum_nights',
       'has_availability', 'number_of_reviews', 'review_scores_rating',
       'review_scores_accuracy', 'review_scores_cleanliness',
       'review_scores_checkin', 'review_scores_communication',
```

```
       'review_scores_location', 'review_scores_value', 'license',
       'instant_bookable'],
      dtype='object')
```

[12]:
```
df.head()
```

[12]:

	id	host_is_superhost	host_identity_verified	\
0	11547	f	t	
1	100831	f	t	
2	105891	t	t	
3	106833	f	t	
4	130669	f	f	

	neighbourhood_cleansed	latitude	longitude	property_type	\
0	Calvià	39.51888	2.48182	Entire apartment	
1	Santa Margalida	39.76347	3.16255	Entire house	
2	Maria de la Salut	39.66044	3.07165	Entire townhouse	
3	Sant Llorenç des Cardassar	39.61600	3.30121	Entire villa	
4	Palma de Mallorca	39.56478	2.60333	Private room in apartment	

	room_type	accommodates	bathrooms_text	…	number_of_reviews	\
0	Entire home/apt	2	1 bath	…	103	
1	Entire home/apt	8	3 baths	…	30	
2	Entire home/apt	6	2 baths	…	14	
3	Entire home/apt	4	1 bath	…	9	
4	Private room	2	1 bath	…	0	

	review_scores_rating	review_scores_accuracy	review_scores_cleanliness	\
0	96.0	10.0	9.0	
1	100.0	10.0	10.0	
2	97.0	10.0	10.0	
3	98.0	10.0	10.0	
4	NaN	NaN	NaN	

	review_scores_checkin	review_scores_communication	review_scores_location	\
0	10.0	10.0	10.0	
1	10.0	10.0	10.0	
2	10.0	10.0	9.0	
3	10.0	10.0	9.0	
4	NaN	NaN	NaN	

	review_scores_value	license	instant_bookable
0	10.0	NaN	f
1	10.0	ETV-3045	t
2	10.0	ETV/6127	t
3	9.0	ET/1961	f
4	NaN	NaN	t

```
[5 rows x 27 columns]
```

2.4.1 Columnas de tipo buleano con *strings*

A continuación trataremos aquellas columnas que tienen valores 'f' o 't' y las convertiremos a valores binarios:

[13]:
```
df = df.replace({'t': 1, 'f':0})
```

Columna `bathrooms_text` A continuación se traduce la columna `bathrooms_text` a un valor numérico. En primer lugar vemos qué valores deberemos tratar:

[14]:
```
df_airbnb.bathrooms_text.unique()
```

[14]:
```
array(['1 bath', '3 baths', '2 baths', '1 private bath', '0 baths',
       '1.5 baths', '2 shared baths', '7 baths', '4.5 baths', '2.5 baths',
       '4 baths', '5 baths', 'Shared half-bath', '1.5 shared baths',
       '3.5 baths', '1 shared bath', '6 baths', '8 baths', nan,
       '6.5 baths', '9.5 baths', '5.5 baths', '7.5 baths',
       '12 shared baths', '4 shared baths', '8.5 baths', '0 shared baths',
       '2.5 shared baths', 'Half-bath', '12 baths', '11 baths',
       '13 baths', '9 baths', '3 shared baths', '3.5 shared baths',
       '12.5 baths', '32 baths', '19 baths', 'Private half-bath',
       '13 shared baths', '10 baths', '14 baths', '16 baths'],
      dtype=object)
```

En segundo lugar reemplazamos los "medios baños" por 0.5.

[15]:
```
df.bathrooms_text = df.bathrooms_text.replace({"\w+ half-bath$": "0.5",␣
↪"Half-bath":"0.5"}, regex = True)
df.bathrooms_text.unique()
```

[15]:
```
array(['1 bath', '3 baths', '2 baths', '1 private bath', '0 baths',
       '1.5 baths', '2 shared baths', '7 baths', '4.5 baths', '2.5 baths',
       '4 baths', '5 baths', '0.5', '1.5 shared baths', '1 shared bath',
       '3.5 baths', '6 baths', nan, '6.5 baths', '5.5 baths', '7.5 baths',
       '9.5 baths', '4 shared baths', '8 baths', '0 shared baths',
       '2.5 shared baths', '11 baths', '9 baths', '3 shared baths',
       '3.5 shared baths', '12.5 baths', '32 baths', '8.5 baths',
       '13 shared baths', '12 baths', '10 baths', '13 baths'],
      dtype=object)
```

Ahora extraemos el valor numérico que hay dentro del string y lo almacenamos en una nueva columna.

[16]:
```
df['bathrooms'] = df['bathrooms_text'].str.extract('(\d*\.\d+|\d+)', expand =␣
↪False).astype(float)
df.bathrooms = df.bathrooms.fillna(0)
df.bathrooms.unique()
```

[16]:
```
array([ 1. ,  3. ,  2. ,  0. ,  1.5,  7. ,  4.5,  2.5,  4. ,  5. ,  0.5,
        3.5,  6. ,  6.5,  5.5,  7.5,  9.5,  8. , 11. ,  9. , 12.5, 32. ,
        8.5, 13. , 12. , 10. ])
```

Ahora ya se puede eliminar la columna con los strings.

[17]:
```
df = df.drop(columns = ['bathrooms_text'])
df.columns
```

[17]:
```
Index(['id', 'host_is_superhost', 'host_identity_verified',
       'neighbourhood_cleansed', 'latitude', 'longitude', 'property_type',
       'room_type', 'accommodates', 'bedrooms', 'beds', 'amenities', 'price',
       'minimum_nights', 'maximum_nights', 'has_availability',
       'number_of_reviews', 'review_scores_rating', 'review_scores_accuracy',
       'review_scores_cleanliness', 'review_scores_checkin',
       'review_scores_communication', 'review_scores_location',
       'review_scores_value', 'license', 'instant_bookable', 'bathrooms'],
      dtype='object')
```

[18]:
```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 17181 entries, 0 to 17607
Data columns (total 27 columns):
 #   Column                       Non-Null Count  Dtype
---  ------                       --------------  -----
 0   id                           17181 non-null  int64
 1   host_is_superhost            17179 non-null  float64
 2   host_identity_verified       17179 non-null  float64
 3   neighbourhood_cleansed       17181 non-null  object
 4   latitude                     17181 non-null  float64
 5   longitude                    17181 non-null  float64
 6   property_type                17181 non-null  object
 7   room_type                    17181 non-null  object
 8   accommodates                 17181 non-null  int64
 9   bedrooms                     16911 non-null  float64
 10  beds                         17097 non-null  float64
 11  amenities                    17181 non-null  object
 12  price                        17181 non-null  float64
 13  minimum_nights               17181 non-null  int64
 14  maximum_nights               17181 non-null  int64
 15  has_availability             17181 non-null  int64
 16  number_of_reviews            17181 non-null  int64
```

```
 17  review_scores_rating         10833 non-null  float64
 18  review_scores_accuracy       10829 non-null  float64
 19  review_scores_cleanliness    10831 non-null  float64
 20  review_scores_checkin        10827 non-null  float64
 21  review_scores_communication  10829 non-null  float64
 22  review_scores_location       10828 non-null  float64
 23  review_scores_value          10827 non-null  float64
 24  license                      11184 non-null  object
 25  instant_bookable             17181 non-null  int64
 26  bathrooms                    17181 non-null  float64
dtypes: float64(15), int64(7), object(5)
memory usage: 3.7+ MB
```

2.4.2 Columna *license*

La siguiente columna a tratar será la de licencia. Vamos a codificar la columna en licencia o no licencia:

[19]:
```
df.license.unique()
```

[19]:
```
array([nan, 'ETV-3045', 'ETV/6127', …, 'ETV/5754', 'LIZE84/2017',
       '00551ETV'], dtype=object)
```

[20]:
```
df.license = df.license.fillna(0)
df.license[df.license != 0] = 1
df.license.astype(int)
df.license
```

[20]:
```
0        0
1        1
2        1
3        1
4        0
        ..
17603    1
17604    0
17605    1
17606    0
17607    0
Name: license, Length: 17181, dtype: object
```

Antes de empezar con los tipos de alojamiento o habitación, vamos a realizar una separación de `amenities` y haremos un conteo de cada uno para las distintas propiedades. Para ello se definirá un nuevo dataframe que luego podremos concatenar con el anterior.

2.4.3 Columna *amenities*

Para la creación de este dataframe vamos a utilizar la funcion `CountVectorizer` del paquete `scikit-learn`. Se ha entendido su funcionamiento a partir de una búsqueda en *stack overflow* y posteriormente de las instrucciones de la librería (enlace).

Esta función permite identificar distintas etiquetas de un *string* y además genera una matriz para identificar las posiciones de éstas. Utilizando estas dos características podemos generar el nuevo *data frame*.

En primer lugar extraemos la matriz de posiciones y los valores de las etiquetas:

[21]:
```
vectorizer = CountVectorizer(tokenizer=lambda row: row.split(','))

matriz = vectorizer.fit_transform(df.amenities)
etiquetas = vectorizer.get_feature_names()
```

Ahora corregimos algunas de las etiquetas, que, por cómo estan construidos los datos, incluyen algunos caracteres que las harán difíciles de utilizar:

[22]:
```
for ind, amenit in enumerate(etiquetas):
    amenit_limpias = amenit.replace('"','').replace('[','').replace(']','').
 ↪strip()
    etiquetas[ind] = amenit_limpias
```

Finalmente creamos el dataframe nuevo y borramos las columnas a reemplazar:

[23]:
```
df_amenities = pd.DataFrame(matriz.toarray(),columns=etiquetas)
df_amenities.drop('',axis=1,inplace=True)
df_amenities.columns
```

[23]:
```
Index(['air conditioning', 'air conditioning', 'baby bath', 'baby bath',
       'baby monitor', 'babysitter recommendations',
       'babysitter recommendations', 'baking sheet', 'balcony',
       'barbecue utensils',
       …
       'record player', 'room-darkening shades', 'shampoo', 'smoke alarm',
       'table corner guards', 'terrace', 'tv', 'tv', 'washer', 'wifi'],
      dtype='object', length=229)
```

Comprobamos si hay columnas duplicadas:
(Para hacerlo más intuitivo, la siguiente línea devuelve un true si hay columnas duplicadas y un false si no las hay)

[24]:
```
not(len(df_amenities.columns) == len(df_amenities.columns.unique()))
```

[24]:
```
True
```

Efectivamente, hay alguna o algunas columnas duplicadas. El paso siguiente es convertir estas

múltiples columnas en una sola, de manera que esta indique si el hospedaje tiene o no esta característica, de esta manera conseguimos columnas que coinciden con la técnica de "OneHotEncoding".

[25]:
```
cols = df_amenities.columns.tolist()
new_df = pd.DataFrame()

for ncol in range(len(cols)):
    col_name = cols[ncol]
    if col_name not in new_df.columns:
        indices = [i for i, x in enumerate(cols) if x == col_name]
        new_df.loc[:,col_name] = df_amenities.iloc[:,indices].sum(axis=1).
↪tolist()

new_df[new_df > 0] = 1 #Convertimos a binario
```

Realizamos de nuevo la comprobación, para estar seguros de que no hay duplicados:
(En este caso un valor True representa que no hay duplicaciones)

[26]:
```
(new_df.columns == new_df.columns.unique()).all()
```

[26]:
```
True
```

Ahora que tenemos la categoría de `amenities` tratada, se procede a la agregación de estas columnas al *dataframe* original y la eliminación de la columna que contenía la información. Ello se realiza mediante una concatenación de columnas ya que no se ha alterado el orden de los índices en todo el proceso.

[27]:
```
df = df.drop(columns = ['amenities'])
df = pd.concat([df, new_df], axis=1)
```

[28]:
```
df.head()
```

[28]:

	id	host_is_superhost	host_identity_verified	\
0	11547.0	0.0	1.0	
1	100831.0	0.0	1.0	
2	105891.0	1.0	1.0	
3	106833.0	0.0	1.0	
4	130669.0	0.0	0.0	

	neighbourhood_cleansed	latitude	longitude	property_type	\
0	Calvià	39.51888	2.48182	Entire apartment	
1	Santa Margalida	39.76347	3.16255	Entire house	
2	Maria de la Salut	39.66044	3.07165	Entire townhouse	
3	Sant Llorenç des Cardassar	39.61600	3.30121	Entire villa	
4	Palma de Mallorca	39.56478	2.60333	Private room in apartment	

	room_type	accommodates	bedrooms	…	trash compactor	tv	\
0	Entire home/apt	2.0	1.0	…	0.0	1.0	

```
1  Entire home/apt           8.0       4.0  …              0.0  1.0
2  Entire home/apt           6.0       3.0  …              0.0  1.0
3  Entire home/apt           4.0       2.0  …              0.0  1.0
4     Private room           2.0       1.0  …              0.0  1.0

   walk in closet  washer  waterfront  wifi  window guards  wine cooler  \
0             0.0     1.0         0.0   1.0            0.0          0.0
1             0.0     1.0         0.0   1.0            0.0          0.0
2             0.0     1.0         0.0   1.0            0.0          0.0
3             0.0     0.0         0.0   1.0            0.0          0.0
4             0.0     1.0         0.0   1.0            0.0          0.0

   wood-burning fireplace  terrace
0                     0.0      0.0
1                     0.0      0.0
2                     0.0      0.0
3                     0.0      0.0
4                     0.0      0.0

[5 rows x 154 columns]
```

2.4.4 Columnas de tipo de alojamiento y propiedad

A continuación se procede a analizar cuál de las columnas `property_type` o `room_type` conviene más tratar y posteriormente se aplicará "OneHotEncoding. Para ello, analizamos las dos columnas.

En primer lugar analizamos `room_type`:

[29]:
```
df.room_type.unique()
```

[29]:
```
array(['Entire home/apt', 'Private room', 'Hotel room', nan,
       'Shared room'], dtype=object)
```

[30]:
```
fig, ax = plt.subplots()
sorted_average = df.groupby('room_type').mean().
 ↪sort_values('price',ascending=True)
ax = sns.boxplot(x="room_type", y="price", data=df, order=sorted_average.index)
ax.set_xticklabels(ax.get_xticklabels(),rotation=90)
```

[30]:
```
[Text(0, 0, 'Shared room'),
 Text(1, 0, 'Private room'),
 Text(2, 0, 'Hotel room'),
 Text(3, 0, 'Entire home/apt')]
```

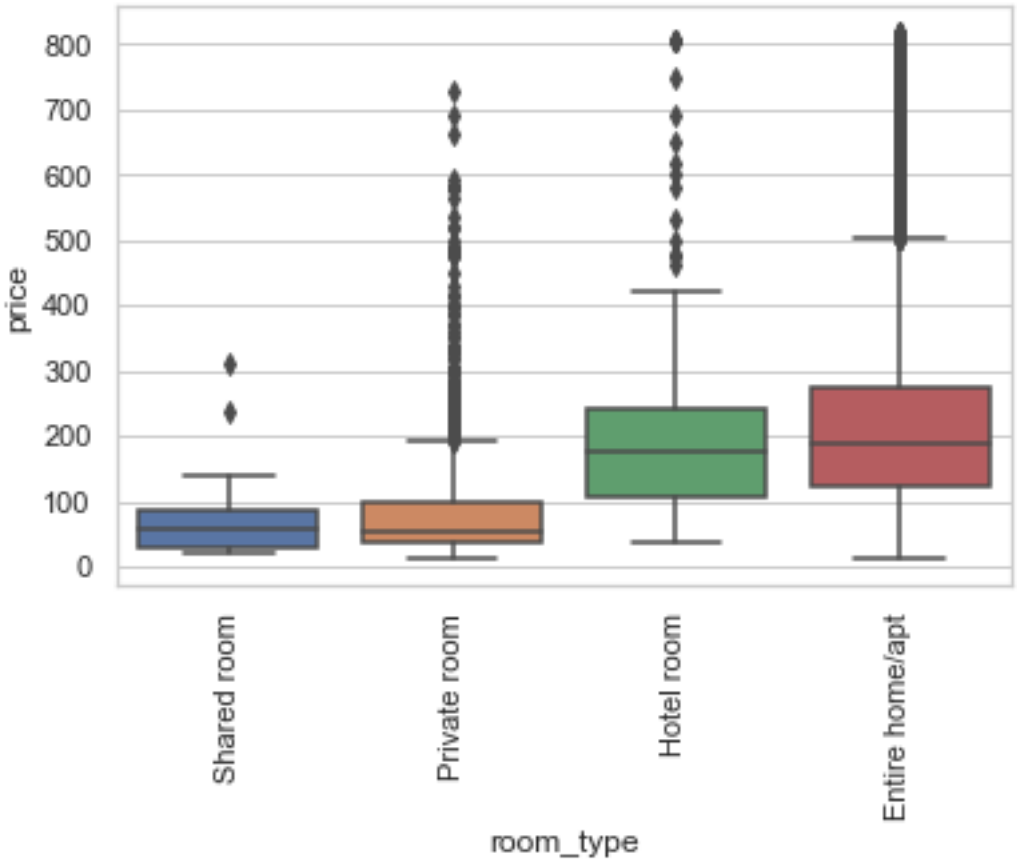

[31]:
```
df_rooms = pd.get_dummies(df.room_type)
df_rooms
```

[31]:

	Entire home/apt	Hotel room	Private room	Shared room
0	1	0	0	0
1	1	0	0	0
2	1	0	0	0
3	1	0	0	0
4	0	0	1	0
…	…	…	…	…
17603	1	0	0	0
17604	1	0	0	0
17605	1	0	0	0
17606	0	0	1	0
17607	1	0	0	0

[17603 rows x 4 columns]

Con el nuevo dataframe creado únicamente falta eliminar la columna previa y añadir las nuevas ya codificadas.

[32]:
```
df = df.drop(columns = ['room_type'])
df = pd.concat([df, df_rooms], axis=1)
df.head()
```

[32]:

	id	host_is_superhost	host_identity_verified	\
0	11547.0	0.0	1.0	
1	100831.0	0.0	1.0	
2	105891.0	1.0	1.0	
3	106833.0	0.0	1.0	
4	130669.0	0.0	0.0	

	neighbourhood_cleansed	latitude	longitude	property_type	\
0	Calvià	39.51888	2.48182	Entire apartment	
1	Santa Margalida	39.76347	3.16255	Entire house	
2	Maria de la Salut	39.66044	3.07165	Entire townhouse	
3	Sant Llorenç des Cardassar	39.61600	3.30121	Entire villa	
4	Palma de Mallorca	39.56478	2.60333	Private room in apartment	

	accommodates	bedrooms	beds	…	waterfront	wifi	window guards	\
0	2.0	1.0	1.0	…	0.0	1.0	0.0	
1	8.0	4.0	7.0	…	0.0	1.0	0.0	
2	6.0	3.0	4.0	…	0.0	1.0	0.0	
3	4.0	2.0	4.0	…	0.0	1.0	0.0	
4	2.0	1.0	2.0	…	0.0	1.0	0.0	

	wine cooler	wood-burning fireplace	terrace	Entire home/apt	Hotel room	\
0	0.0	0.0	0.0	1	0	
1	0.0	0.0	0.0	1	0	
2	0.0	0.0	0.0	1	0	
3	0.0	0.0	0.0	1	0	
4	0.0	0.0	0.0	0	0	

	Private room	Shared room
0	0	0
1	0	0
2	0	0
3	0	0
4	1	0

[5 rows x 157 columns]

En segundo lugar analizamos `property_type`:

[33]:
```
df.property_type.unique()
```

[33]:
```
array(['Entire apartment', 'Entire house', 'Entire townhouse',
       'Entire villa', 'Private room in apartment', 'Entire guesthouse',
```

```
       'Private room in guest suite', 'Private room in villa',
       'Entire loft', 'Entire cottage', 'Castle', 'Entire condominium',
       'Room in boutique hotel', 'Private room', 'Private room in house',
       'Entire chalet', 'Entire cabin', nan,
       'Private room in condominium', 'Entire guest suite',
       'Private room in boat', 'Private room in cottage', 'Camper/RV',
       'Boat', 'Private room in townhouse', 'Private room in hostel',
       'Private room in bed and breakfast', 'Entire serviced apartment',
       'Private room in guesthouse', 'Shared room in apartment',
       'Farm stay', 'Room in serviced apartment',
       'Room in bed and breakfast', 'Private room in chalet',
       'Entire bungalow', 'Room in hotel', 'Island',
       'Shared room in igloo', 'Private room in farm stay',
       'Shared room in bed and breakfast', 'Entire bed and breakfast',
       'Entire place', 'Room in aparthotel', 'Entire vacation home',
       'Private room in bungalow', 'Shared room in house', 'Earth house',
       'Entire floor', 'Room in hostel', 'Room in resort',
       'Room in nature lodge', 'Private room in cabin', 'Tiny house',
       'Shared room in condominium', 'Shared room in guesthouse',
       'Private room in hut', 'Entire resort', 'Windmill', 'Dome house',
       'Private room in loft', 'Private room in serviced apartment',
       'Private room in earth house', 'Private room in casa particular',
       'Casa particular', 'Cave', 'Private room in castle',
       'Private room in resort', 'Private room in dome house',
       'Private room in tiny house', 'Houseboat',
       'Shared room in farm stay', 'Room in heritage hotel',
       'Private room in island', 'Shared room in townhouse', 'Barn'],
      dtype=object)
```

[34]:
```
fig, ax = plt.subplots(figsize=(20, 20))
sorted_average = df.groupby('property_type').mean().
 ↪sort_values('price',ascending=True)
ax = sns.boxplot(x="property_type", y="price", data=df, order=sorted_average.
 ↪index)
ls = ax.get_xticklabels()
_ = ax.set_xticklabels(ls,rotation=90)
```

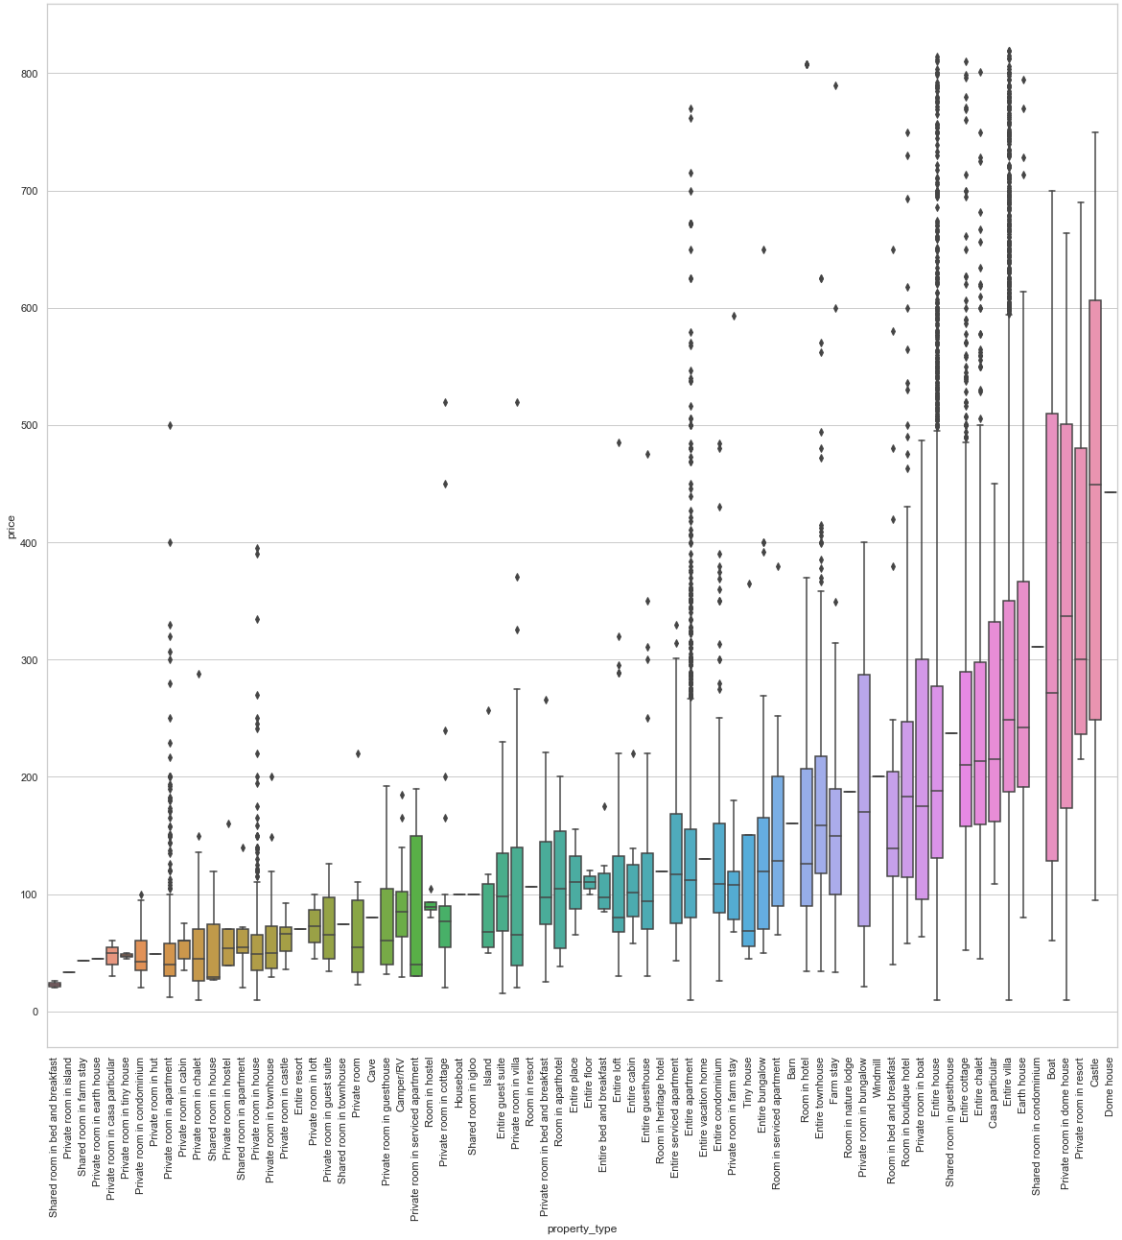

La columna de tipo de propiedad, aunque intuitivamente tiene relevancia para el análisis, contiene una alta variabilidad y al ver la distribución estadística de los valores por etiqueta no parece un sistema fiable, ni siquiera ordenado por la media del precio agrupado por tipo de propiedad. Por todo esto se decide eliminar la columna.

[35]:
```
df = df.drop(columns = ['property_type']) #Se elimina la columna descartada
```

2.4.5 Columna `neighbourhood_cleansed`:

Esta columna accede a las propiedades de "barrio", que son menos localizadas que latitud y longitud. Esta ligera deslocalización puede ser beneficiosa a la hora de aplicar el modelo.

[36]:
```
df.neighbourhood_cleansed.unique()
```

[36]:
```
array(['Calvià', 'Santa Margalida', 'Maria de la Salut',
       'Sant Llorenç des Cardassar', 'Palma de Mallorca', 'Selva',
       'Esporles', 'Banyalbufar', 'Manacor', 'Sa Pobla', 'Alcúdia',
       'Pollença', 'Artà', 'Santanyí', 'Fornalutx', 'Campos', 'Llucmajor',
       'Sineu', 'Lloseta', 'Marratxí', 'Felanitx', 'Llubí', 'Muro',
       'Lloret de Vistalegre', 'Ariany', 'Campanet', 'Capdepera',
       'Puigpunyent', 'Binissalem', 'Valldemossa', 'Algaida',
       'Son Servera', 'Sóller', 'Ses Salines', nan, 'Mancor de la Vall',
       'Andratx', 'Santa María del Camí', 'Inca', 'Costitx', 'Bunyola',
       'Deyá', 'Búger', 'Porreres', 'Alaró', 'Montuïri', 'Escorca',
       'Petra', 'Consell', 'Sencelles', 'Vilafranc de Bonany',
       'Estellencs', 'Sant Joan', 'Santa Eugènia'], dtype=object)
```

[37]:
```
fig, ax = plt.subplots(figsize=(20, 20))
sorted_average = df.groupby('neighbourhood_cleansed').mean().
 ↪sort_values('price',ascending=True)
ax = sns.boxplot(x="neighbourhood_cleansed", y="price", data=df,␣
 ↪order=sorted_average.index)
_ = ax.set_xticklabels(ax.get_xticklabels(),rotation=90)
```

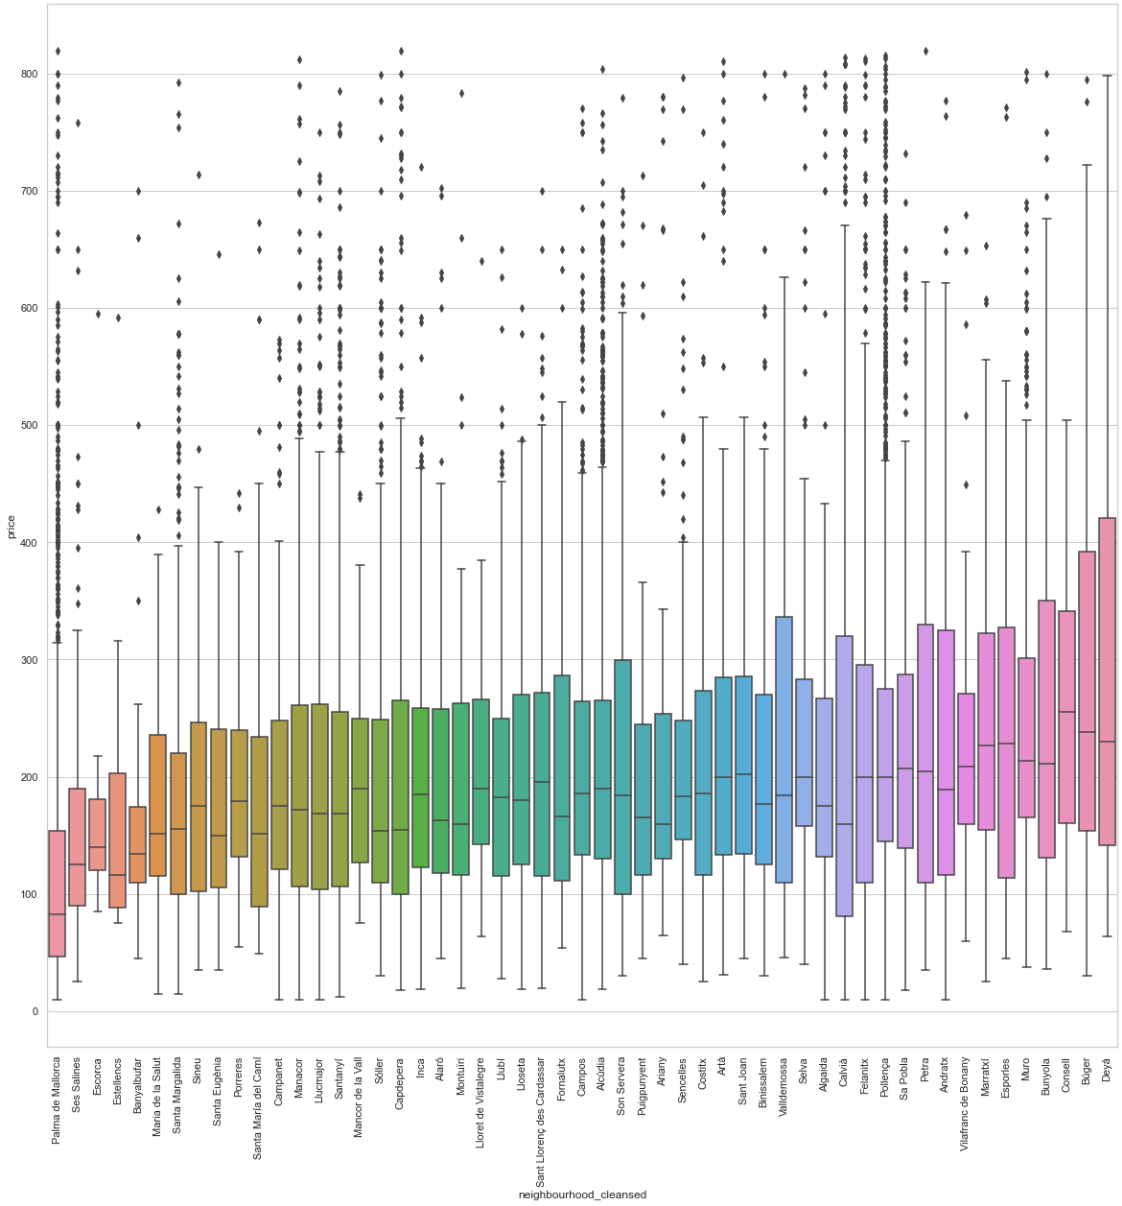

Según el *boxplot* hay una linealidad entre el lugar y la distribución de la media del precio, pese a los *outliers*. Por tanto, se decide que es una columna de utilidad. A continuación, se trata con la técnica *OHE*.

[38]:
```
df_neigh = pd.get_dummies(df.neighbourhood_cleansed)
df_neigh
```

[38]:

	Alaró	Alcúdia	Algaida	Andratx	Ariany	Artà	Banyalbufar	\
0	0	0	0	0	0	0	0	
1	0	0	0	0	0	0	0	
2	0	0	0	0	0	0	0	

```
3          0        0        0        0       0     0            0
4          0        0        0        0       0     0            0
…      …       …       …       …     …   …           …
17603      0        0        0        0       0     0            0
17604      0        0        0        0       0     0            0
17605      0        0        0        0       0     0            0
17606      0        0        0        1       0     0            0
17607      0        0        0        0       0     0            0

       Binissalem  Bunyola  Búger  …  Santa María del Camí  Santanyí  Selva  \
0               0        0      0  …                    0         0      0
1               0        0      0  …                    0         0      0
2               0        0      0  …                    0         0      0
3               0        0      0  …                    0         0      0
4               0        0      0  …                    0         0      0
…           …       …    …    …  …                …       …    …
17603           0        0      0  …                    0         0      0
17604           0        0      0  …                    0         0      0
17605           0        0      0  …                    0         0      1
17606           0        0      0  …                    0         0      0
17607           0        0      0  …                    0         0      0

       Sencelles  Ses Salines  Sineu  Son Servera  Sóller  Valldemossa  \
0              0            0      0            0       0            0
1              0            0      0            0       0            0
2              0            0      0            0       0            0
3              0            0      0            0       0            0
4              0            0      0            0       0            0
…          …          …    …          …     …          …
17603          0            0      0            0       0            0
17604          0            0      0            0       0            0
17605          0            0      0            0       0            0
17606          0            0      0            0       0            0
17607          0            0      0            0       0            0

       Vilafranc de Bonany
0                        0
1                        0
2                        0
3                        0
4                        0
…                    …
17603                    0
17604                    0
17605                    0
17606                    0
17607                    0
```

```
[17603 rows x 53 columns]
```

[39]:
```
df = df.drop(columns = ['neighbourhood_cleansed'])
df = pd.concat([df, df_neigh], axis=1)
df.head()
```

[39]:

	id	host_is_superhost	host_identity_verified	latitude	longitude	\
0	11547.0	0.0	1.0	39.51888	2.48182	
1	100831.0	0.0	1.0	39.76347	3.16255	
2	105891.0	1.0	1.0	39.66044	3.07165	
3	106833.0	0.0	1.0	39.61600	3.30121	
4	130669.0	0.0	0.0	39.56478	2.60333	

	accommodates	bedrooms	beds	price	minimum_nights	…	\
0	2.0	1.0	1.0	89.0	5.0	…	
1	8.0	4.0	7.0	175.0	7.0	…	
2	6.0	3.0	4.0	140.0	6.0	…	
3	4.0	2.0	4.0	200.0	5.0	…	
4	2.0	1.0	2.0	110.0	2.0	…	

	Santa María del Camí	Santanyí	Selva	Sencelles	Ses Salines	Sineu	\
0	0	0	0	0	0	0	
1	0	0	0	0	0	0	
2	0	0	0	0	0	0	
3	0	0	0	0	0	0	
4	0	0	0	0	0	0	

	Son Servera	Sóller	Valldemossa	Vilafranc de Bonany
0	0	0	0	0
1	0	0	0	0
2	0	0	0	0
3	0	0	0	0
4	0	0	0	0

```
[5 rows x 208 columns]
```

2.5 Columnas de latitud y longitud

El siguiente paso es ver si la ubicación precisa de los hospedajes tiene algún tipo de colinearidad con el precio. Para empezar vamos a ver la distribución de los alojamientos sobre la isla:

[40]:
```
box = ((2.2165, 3.6118, 39.2152, 39.9982)) #lonmin,lonmax,latmin,latmax
mapimg = plt.imread(path_img_map)
fig, ax = plt.subplots(figsize = (8,7))
```

```
ax.scatter(df.longitude, df.latitude, zorder=1, c='b', s=1)
ax.set_title('Hospedajes sobre el mapa')
ax.set_xlabel('Longitud')
ax.set_xlim(box[0],box[1])
ax.set_ylabel('Latitud')
ax.set_ylim(box[2],box[3])
ax.imshow(mapimg, zorder=0, extent = box, aspect= 'equal')
```

[40]: `<matplotlib.image.AxesImage at 0x7f8d257dd910>`

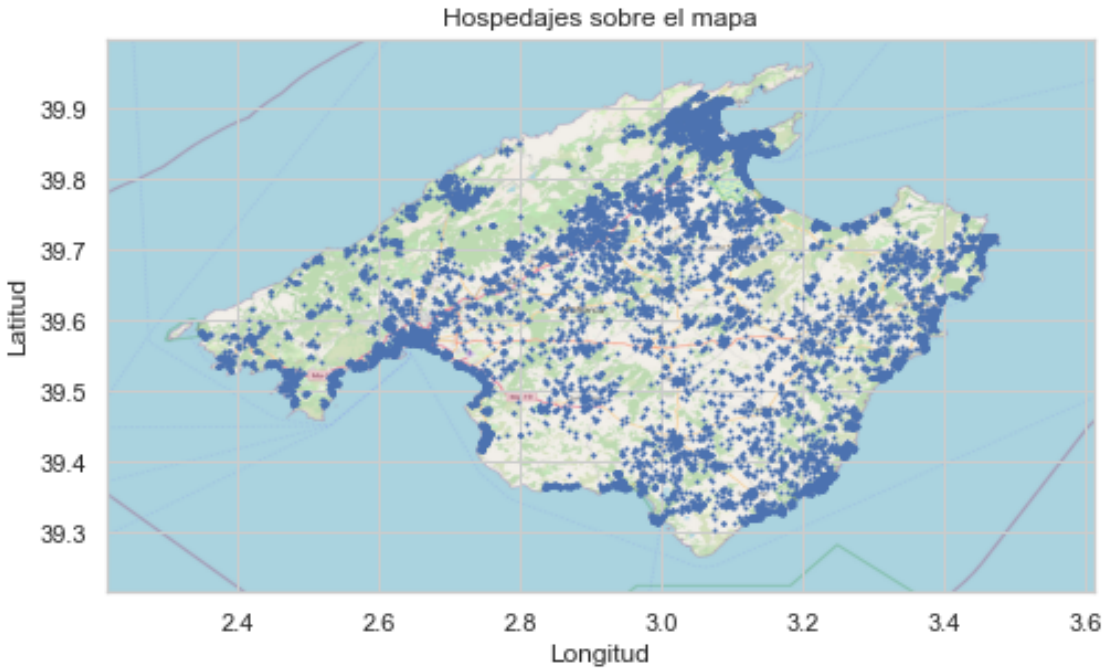

Vista la distribución general de los hospedajes en la isla, aunque hay algunos núcleos, no se puede decir que la distribución a lo largo de los ejes de latitud y longitud sea relevante. A diferencia de las concentraciones en algunas zonas, que probablemente se vean representadas por la agrupación por vecindarios mejor que por estas dos variables. Aún así veamos si hay algún tipo de relación entre ellas y el precio con un *pairplot*;

[41]:
```
sns.pairplot(df[['latitude', 'longitude','price']])
```

[41]: `<seaborn.axisgrid.PairGrid at 0x7f8d252dd2d0>`

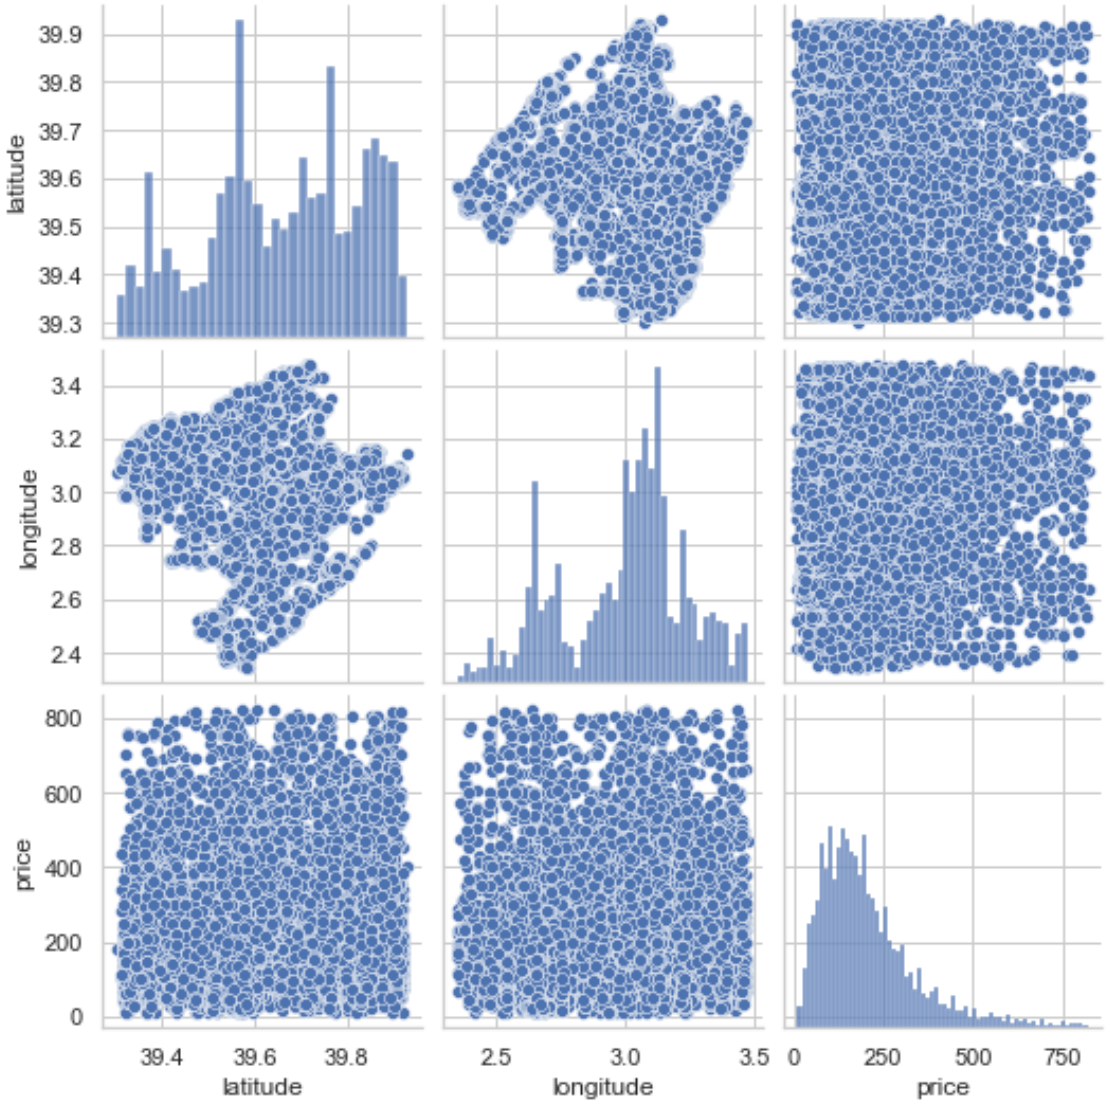

Como decíamos no se ve ninguna relación. Tampoco con el *pairplot*. Podemos decir que las columnas de latitud y longitud no tienen relevancia para el estudio, por tanto, las eliminamos.

[42]:
```
df = df.drop(columns = ['latitude', 'longitude'])
```

Estudio final de valores nulos A continuación se presenta la información sobre el *dataset* ya modificado:

[43]:
```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 17603 entries, 0 to 17607
Columns: 206 entries, id to Vilafranc de Bonany
```

```
dtypes: float64(148), object(1), uint8(57)
memory usage: 21.6+ MB
```

Convertimos las variables al tipo más óptimo utilizando una función de la librería `pandas`: *convert_dtypes*.

[44]:
```
df.convert_dtypes()
```

[44]:
```
             id  host_is_superhost  host_identity_verified  accommodates  \
0         11547                  0                       1             2
1        100831                  0                       1             8
2        105891                  1                       1             6
3        106833                  0                       1             4
4        130669                  0                       0             2
…           …                  …                       …           …
17603  45489412                  0                       1             6
17604  45489550                  0                       1             9
17605  45493152                  0                       1             6
17606  45496032                  0                       0             2
17607  45499210                  0                       0             6

       bedrooms  beds  price  minimum_nights  maximum_nights  \
0             1     1   89.0               5              60
1             4     7  175.0               7             365
2             3     4  140.0               6             365
3             2     4  200.0               5             365
4             1     2  110.0               2             365
…           …   …     …               …              …
17603         3     4  195.0               1             365
17604         5     8  110.0               1            1125
17605         3     4  179.0               1             365
17606         1     1   42.0               1               7
17607         2     4  100.0               5            1120

       has_availability  …  Santa María del Camí  Santanyí  Selva  \
0                     1  …                     0         0      0
1                     1  …                     0         0      0
2                     1  …                     0         0      0
3                     1  …                     0         0      0
4                     1  …                     0         0      0
…                   …  …                     …       …    …
17603                 1  …                     0         0      0
17604                 1  …                     0         0      0
17605                 1  …                     0         0      1
17606                 1  …                     0         0      0
17607                 1  …                     0         0      0

       Sencelles  Ses Salines  Sineu  Son Servera  Sóller  Valldemossa  \
```

```
0              0            0      0            0       0            0
1              0            0      0            0       0            0
2              0            0      0            0       0            0
3              0            0      0            0       0            0
4              0            0      0            0       0            0
…            …          …      …          …       …          …
17603          0            0      0            0       0            0
17604          0            0      0            0       0            0
17605          0            0      0            0       0            0
17606          0            0      0            0       0            0
17607          0            0      0            0       0            0

       Vilafranc de Bonany
0                        0
1                        0
2                        0
3                        0
4                        0
…                      …
17603                    0
17604                    0
17605                    0
17606                    0
17607                    0

[17603 rows x 206 columns]
```

Ahora que ya se ha visto la forma del dataset, falta hacer un último análisis de valores nulos.

[45]:
```
nan_df = pd.DataFrame(df.isna().sum())
nan_df.reset_index(level = 0, inplace= True)
nan_df.columns = ['columnas', 'num_nans']
nan_df
```

[45]:
```
                    columnas  num_nans
0                         id       422
1          host_is_superhost       424
2     host_identity_verified       424
3               accommodates       422
4                   bedrooms       692
..                        …       …
201                   Sineu         0
202             Son Servera         0
203                  Sóller         0
204             Valldemossa         0
205     Vilafranc de Bonany         0
```

```
[206 rows x 2 columns]
```

[46]:
```
fig, ax = plt.subplots(figsize=(20, 20))
ax = sns.barplot(x = nan_df.columnas, y= nan_df.num_nans, data=nan_df)
ax.set_xticklabels(ax.get_xticklabels(),rotation=90)
ax.set_title('Cantidad de NaNs por columna')
```

[46]:
```
Text(0.5, 1.0, 'Cantidad de NaNs por columna')
```

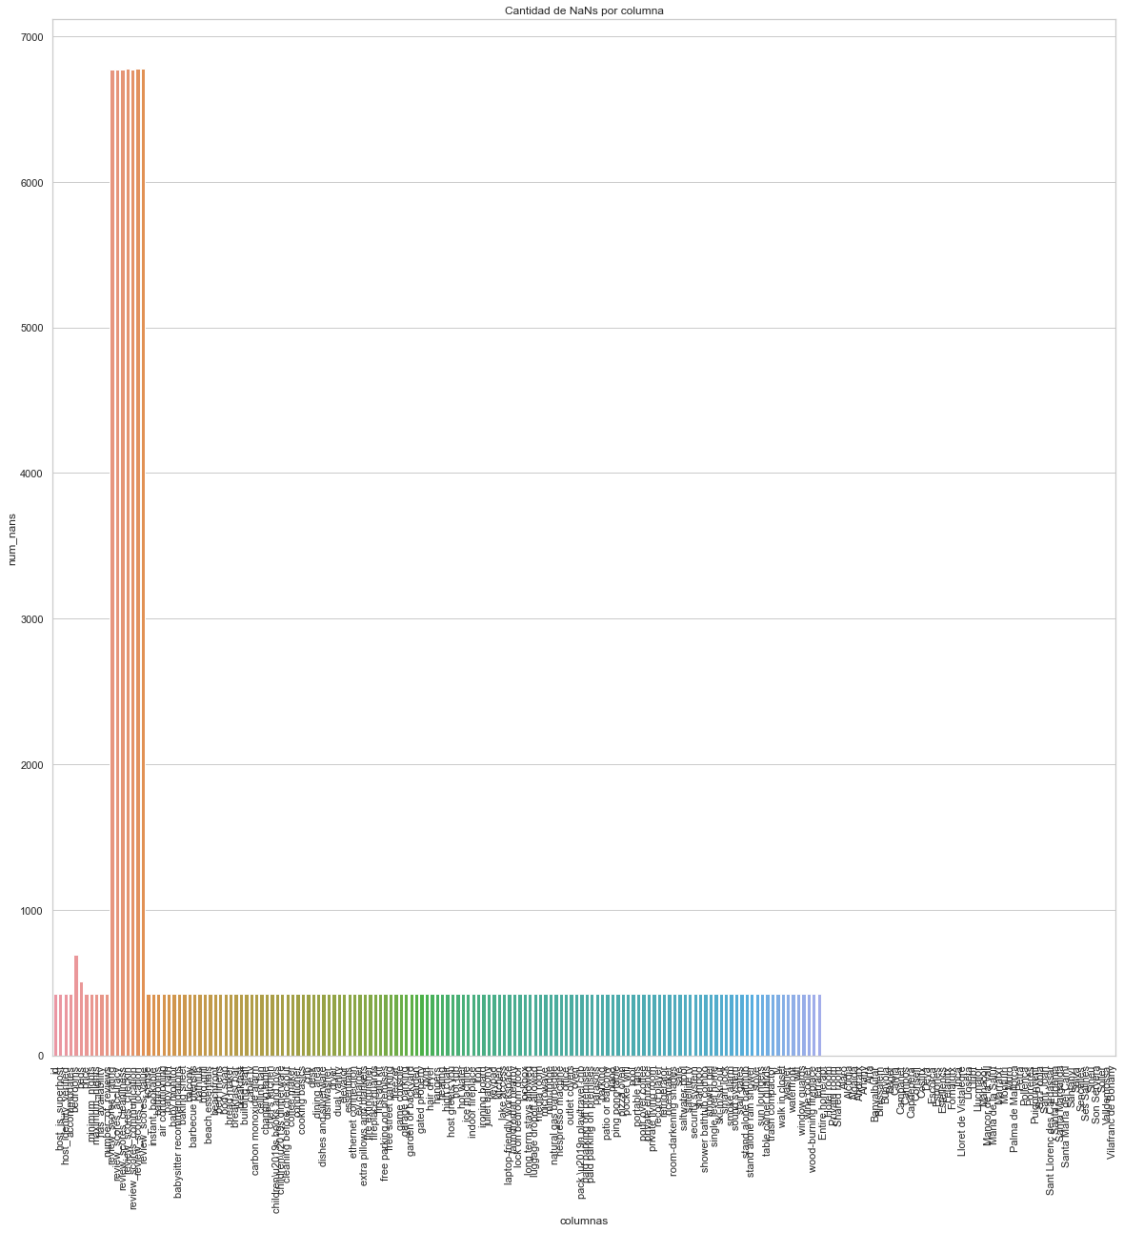

Teniendo en cuenta la longitud del dataset, se puede identificar una serie de columnas que tienen

gran cantidad de nans y que, por tanto no aportan información. Se identifican a continuación utilizando un plot reducido:

[47]:
```
fig, ax = plt.subplots()
aux = nan_df.loc[nan_df.num_nans > 1000,:]
ax = sns.barplot(x = aux.columnas, y= aux.num_nans, data=aux)
_ = ax.set_xticklabels(ax.get_xticklabels(),rotation=90)
```

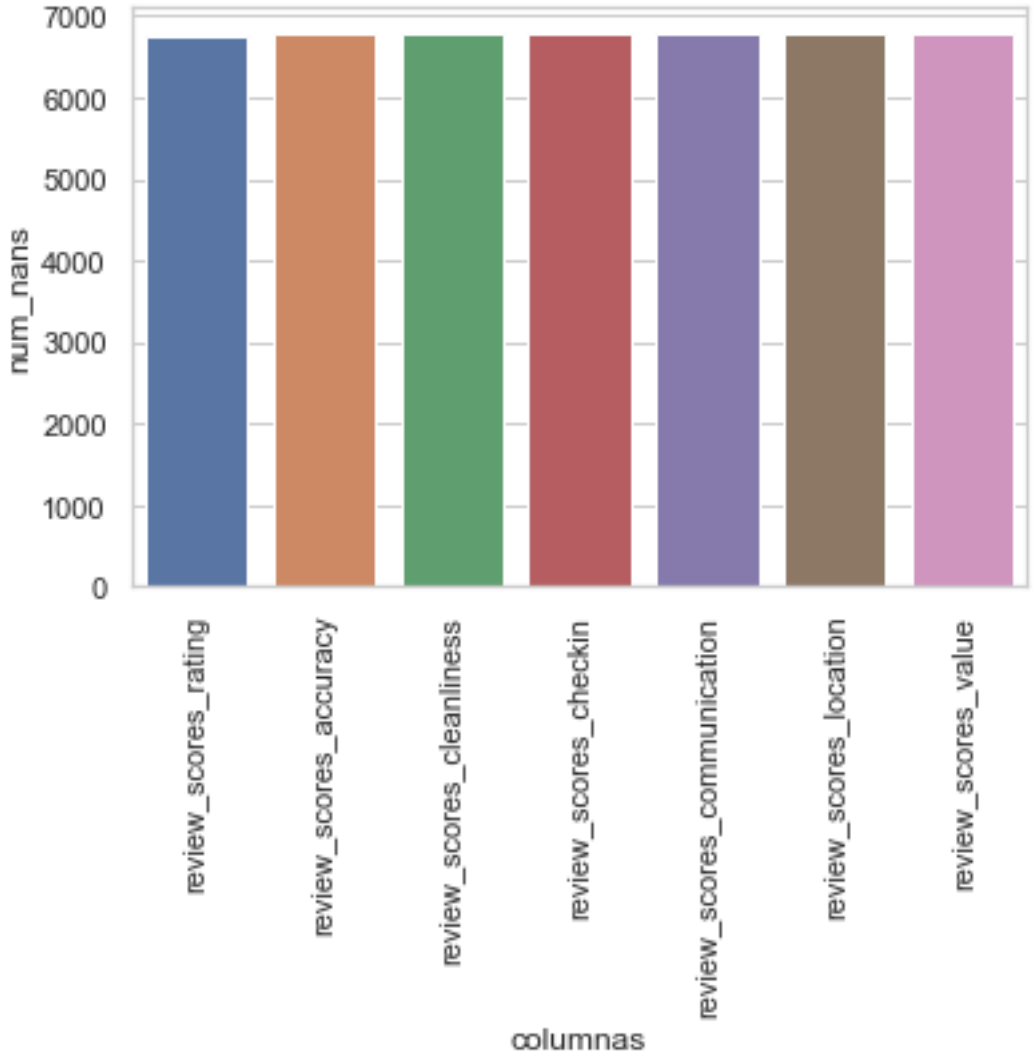

[48]:
```
aux.num_nans.max() / len(df) * 100
```

[48]:
```
38.493438618417315
```

Eliminar las filas con NaNs del dataset significaría perder un 40% de los datos. La mejor manera de realizar esta operación es eliminar las columnas, que aportan poca información al análisis.

[49]:
```
columnas_a_borrar = nan_df.loc[nan_df.num_nans > 1000,:].columnas.tolist()
df = df.drop(columns = columnas_a_borrar)
df.head()
```

[49]:

	id	host_is_superhost	host_identity_verified	accommodates	\
0	11547.0	0.0	1.0	2.0	
1	100831.0	0.0	1.0	8.0	
2	105891.0	1.0	1.0	6.0	
3	106833.0	0.0	1.0	4.0	
4	130669.0	0.0	0.0	2.0	

	bedrooms	beds	price	minimum_nights	maximum_nights	has_availability	\
0	1.0	1.0	89.0	5.0	60.0	1.0	
1	4.0	7.0	175.0	7.0	365.0	1.0	
2	3.0	4.0	140.0	6.0	365.0	1.0	
3	2.0	4.0	200.0	5.0	365.0	1.0	
4	1.0	2.0	110.0	2.0	365.0	1.0	

	…	Santa María del Camí	Santanyí	Selva	Sencelles	Ses Salines	Sineu	\
0	…	0	0	0	0	0	0	
1	…	0	0	0	0	0	0	
2	…	0	0	0	0	0	0	
3	…	0	0	0	0	0	0	
4	…	0	0	0	0	0	0	

	Son Servera	Sóller	Valldemossa	Vilafranc de Bonany
0	0	0	0	0
1	0	0	0	0
2	0	0	0	0
3	0	0	0	0
4	0	0	0	0

[5 rows x 199 columns]

Ahora podemos borrar las filas con nans, que parecen coincidir en muchas de las columnas originales del dataset y que no son una cantidad de datos significativa con respecto al dataset.

[50]:
```
df = df.dropna()
```

Tras la eliminación de NaNs lo comprobamos con el mismo gráfico con el que habíamos estimado la cantidad de NaNs:

[51]:
```
nan_df = pd.DataFrame(df.isna().sum())
nan_df.reset_index(level = 0, inplace= True)
nan_df.columns = ['columnas', 'num_nans']

fig, ax = plt.subplots(figsize=(20, 20))
ax = sns.barplot(x = nan_df.columnas, y= nan_df.num_nans, data=nan_df)
```

```
ax.set_xticklabels(ax.get_xticklabels(),rotation=90)
ax.set_title('Cantidad de NaNs por columna')
```

[51]: `Text(0.5, 1.0, 'Cantidad de NaNs por columna')`

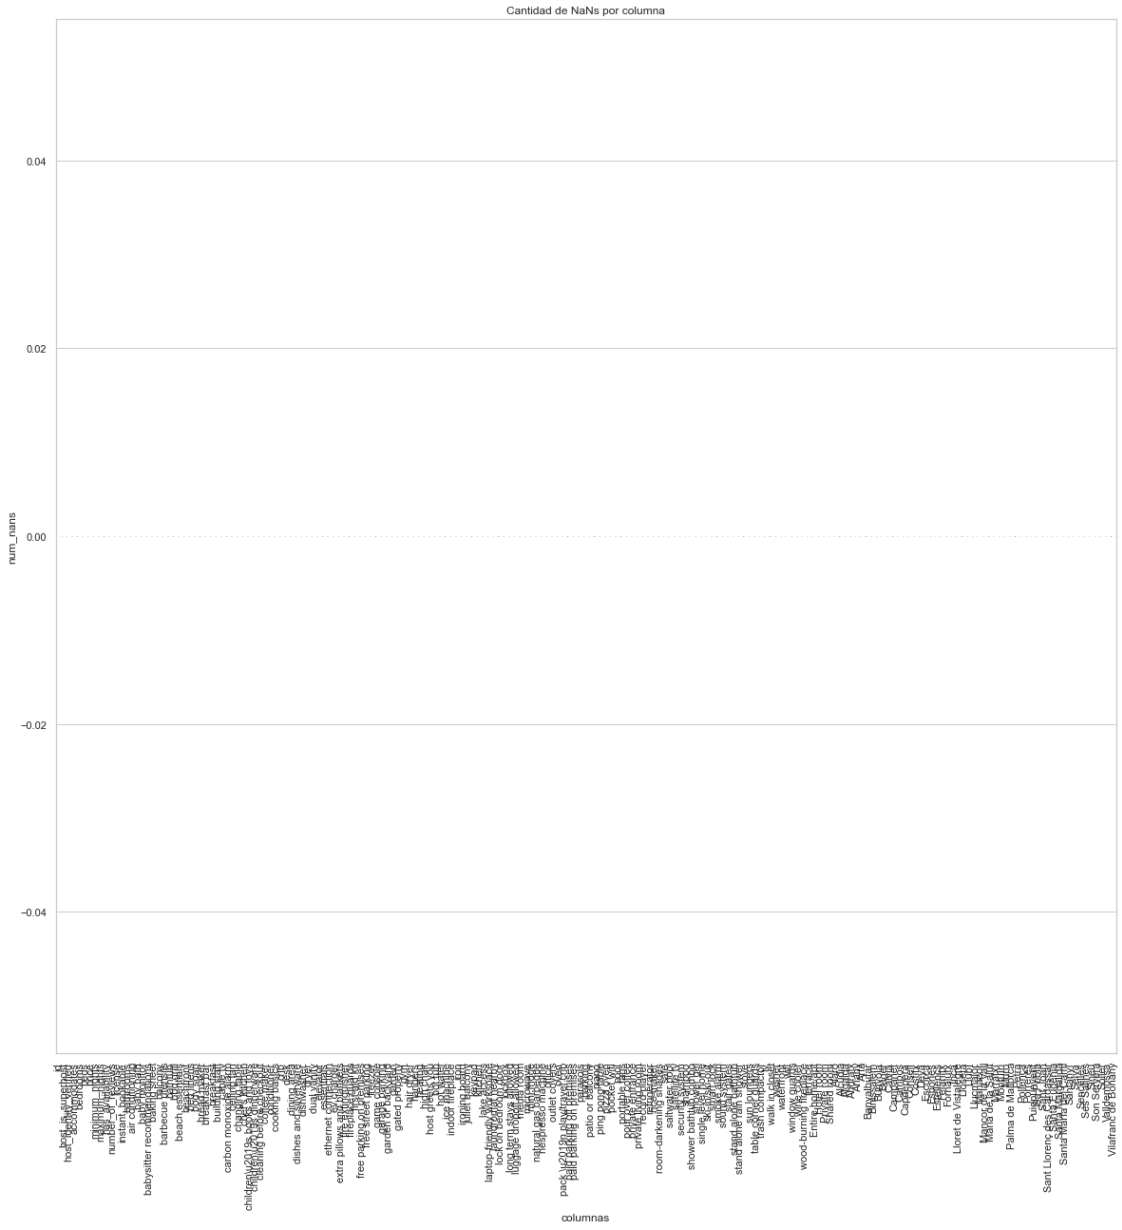

Para poder analizar la influencia del preprocesado en el *dataset*, se vuelven a realizar las comprobaciones iniciales de distribución y de outliers.

En primer lugar analizamos la estadística del precio:

[52]:
```
df.price.describe()
```

[52]:
```
count    16419.00000
mean       209.86629
std        140.12414
min         10.00000
25%        111.00000
50%        177.00000
75%        267.00000
max        819.00000
Name: price, dtype: float64
```

[53]:
```
sns.set_theme(style="whitegrid")
ax = sns.boxplot(y="price", data=df)
```

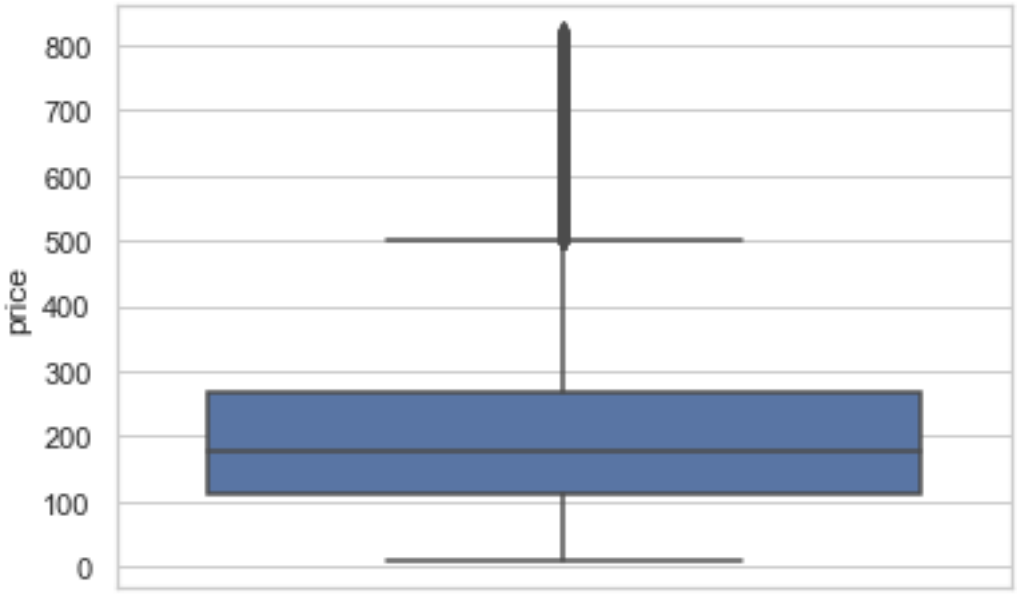

[54]:
```
stats.probplot(df.price, plot=sns.mpl.pyplot)
```

[54]:
```
((array([-3.93146285, -3.71284682, -3.59311497, …,  3.59311497,
          3.71284682,  3.93146285]),
  array([ 10.,  10.,  10., …, 815., 819., 819.])),
 (131.5617713853184, 209.8662896644132, 0.9387085022662417))
```

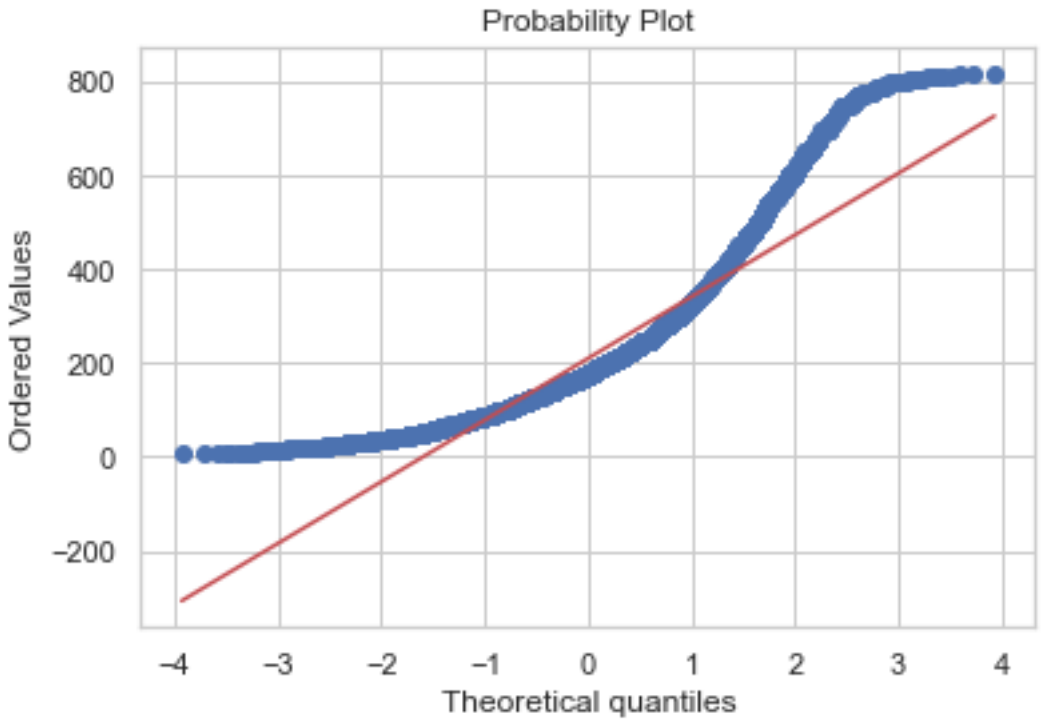

La distribución de precios continua en la misma línea, se pueden apreciar cambios poco significativos, como por ejemplo un descenso de la media (de 244 a 207). De ello se deduce que a pesar del tratamiento, el dataset conserva la estructura inicial, no así la estructura con respecto a la distribución por quantiles, lo que hace necesario un recorte mayor de *outliers*. En este caso nos quedamos únicamente con los datos

[55]:
```
std = df.price.describe()[2]
dfB = df.loc[(df.price <= 3.5*std )]
sns.set_theme(style="whitegrid")
ax = sns.boxplot(y="price", data=dfB)
```

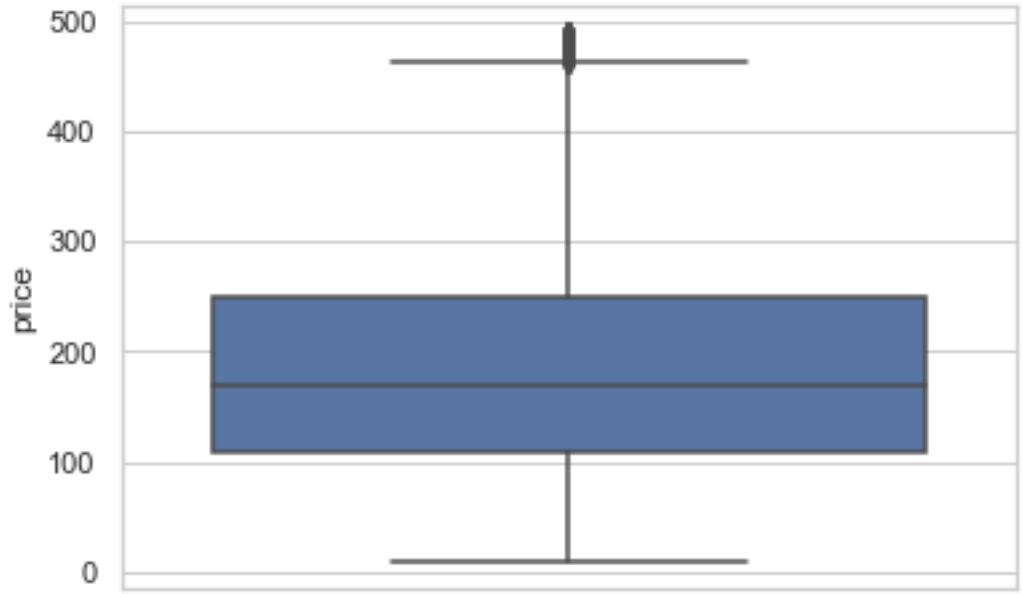

[56]:
```
stats.probplot(dfB.price, plot=sns.mpl.pyplot)
```

[56]:
```
((array([-3.91854322, -3.6992463 , -3.5791117 , …,  3.5791117 ,
          3.6992463 ,  3.91854322]),
  array([ 10.,  10.,  10., …, 490., 490., 490.])),
 (101.24360619490804, 187.57238545080648, 0.9759210757637155))
```

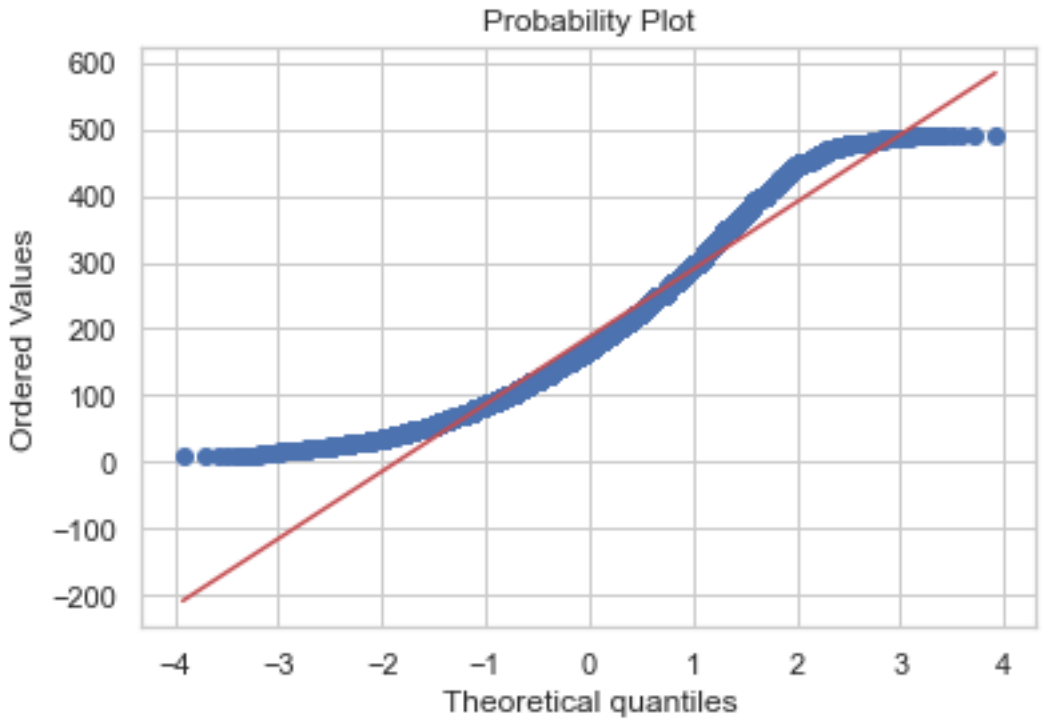

Filtrando por más del 99% de los datos (tres veces y media la desviación estándar) conseguimos limitar el efecto de *outliers* y el ajuste a cuantiles teóricos en la distribución por quantiles.

2.6 Escalado de datos: *train* y *test*

Ya por último se escalan los datos. Para este proceso separaremos en dos *datasets* uno para el entrenamiento y otro para el test. Haremos un entrenamiento de un modelo de escalado (`StandardScaler`), propio de la librería `sklearn` y lo aplicaremos a ambos.

En primer lugar haremos la separación entre los conjuntos de entrenamiento y test:

[57]:
```
df_train, df_test = train_test_split(dfB, test_size= 0.33)
```

A continuación comprobamos que el análisis estadístico de ambos es similar.

[58]:
```
df_train.price.describe()
```

[58]:
```
count    10425.000000
mean       187.536045
std        103.588526
min         10.000000
25%        108.000000
50%        170.000000
75%        250.000000
max        490.000000
Name: price, dtype: float64
```

[59]:
```
df_test.price.describe()
```

[59]:
```
count    5136.000000
mean      187.646149
std       103.996544
min        10.000000
25%       108.000000
50%       170.000000
75%       249.000000
max       490.000000
Name: price, dtype: float64
```

Una vez realizada esta comprobación, se escalan los datos:

[60]:
```
funcion_escalado = StandardScaler().fit(df_train) #entrenamiento con el dataset␣
↪de entrenamiento

df_train_scaled = funcion_escalado.transform(df_train)
```

```
df_test_scaled = funcion_escalado.transform(df_test)
```

[61]:
```
df_train = pd.DataFrame(df_train_scaled, index=df_train.index, columns=df_train.
↪columns)
df_train.describe().price
```

[61]:
```
count    1.042500e+04
mean    -8.894564e-17
std      1.000048e+00
min     -1.713940e+00
25%     -7.678443e-01
50%     -1.692937e-01
75%      6.030296e-01
max      2.920000e+00
Name: price, dtype: float64
```

[62]:
```
df_test = pd.DataFrame(df_test_scaled, index=df_test.index, columns=df_test.
↪columns)
df_test.describe().price
```

[62]:
```
count    5136.000000
mean        0.001063
std         1.003987
min        -1.713940
25%        -0.767844
50%        -0.169294
75%         0.593376
max         2.920000
Name: price, dtype: float64
```

Como se puede observar en las dos cajas anteriores, la media tiende a cero en ambos casos y el resto de valores son aproximadamente iguales en ambos conjuntos de datos.
Con este último tratamiento se cierra el preprocesado y podemos pasar a la selección, entrenamiento y validación del modelo.

3 Modelización

En este apartado utilizaremos los conjuntos ya procesados para la selección del modelo y su entrenamiento. El tipo de modelo seleccionado para este ejercicio es un modelo de regresión.

A lo largo de este apartado se aplicarán distintos modelos de regresión a fin de utilizar dinstintos modelos y poder compararlos. Para esta comparación se utilizarán distintas métricas útiles en modelos de regresión.

Con el fin de poder explicar el funcionamiento de las métricas, se aplicara un modelo simple. Este modelo simple también servirá como punto de partida para seleccionar modelos más complejos y

poder compararlos entre ellos. Los modelos y las métricas utilizadas se extraerán de la librería de `sklearn`.

3.1 Separación en entradas y salidas

A continuación separamos entre entradas y salidas en ambos conjuntos:

[63]:
```
nombres_columnas = df_train.columns
X_train = df_train.loc[:, nombres_columnas != 'price'].to_numpy()
y_train = df_train.loc[:, nombres_columnas == 'price'].to_numpy()
X_test = df_test.loc[:, nombres_columnas != 'price'].to_numpy()
y_test = df_test.loc[:, nombres_columnas == 'price'].to_numpy()

X_train.shape, y_train.shape, X_test.shape, y_test.shape
```

[63]:
```
((10425, 198), (10425, 1), (5136, 198), (5136, 1))
```

3.2 Aplicación de un modelo simple

En primer lugar se aplicará un modelo lineal basado en la minimización del cuadrado de la suma de los residuos, `LinearRegression`. A continuación se presenta la ecuación de minimización que realiza el algoritmo:

$$\min_w ||Xw - y||_2^2$$

Esta formula también podría escribirse como:

$$\min_w ||y_p(w) - y||_2^2$$

El entrenamiento de este modelo devuelve un conjunto de pesos w, que, multiplicado por la entrada X, da lugar a la salida predecida y_p. Estos corresponden a la relevancia de las distintas variables al predecir la salida y en base a la entrada.

[64]:
```
reg = LinearRegression()
reg.fit(X_train, y_train)
y_predict = reg.predict(X_test)
```

3.3 Métricas para modelos de regresión

Utilizando la técnica de *cross-validation*[[2]] comparamos la predicción del modelo con la predicción esperada del conjunto de test. Para esto, deberemos utilizar métricas que nos permitan calificar los distintos ajustes. De entre las métricas más adecuadas para modelos de regresión, se han escogido las métricas más utilizadas. Estas métricas son: * *Mean absolute error* o error absoluto medio * *Mean squared error* o error cuadrado medio * *Median absolute error* o error absoluto mediano * R^2 o coeficiente de determinación

[[2]]Pese a que se puede implementar la técnica mediante una función propia de la librería `sklearn` se ha decidido implementar "a mano" el cálculo de errores con las métricas de la misma librería, para afianzar los conocimientos adquiridos durante el curso.

A continuación se presentan las definiciones y significados de las métricas seleccionadas.

3.3.1 *Mean absolute error (MAE)* o error absoluto medio

Esta métrica calcula la media aritmética de los errores cometidos por el modelo al comparar los valores esperados con los valores predecidos por el modelo. Este error se da en la misma escala que los datos originales y por tanto hace una estimación directa del error cometido al predecir. Se puede calcular con la siguiente fórmula:

$$\mathrm{MAE}(y, \hat{y}) = \frac{1}{n_{\mathrm{samples}}} \sum_{i=0}^{n_{\mathrm{samples}}-1} |y_i - \hat{y}_i|$$

Dónde y_i son los valores esperados y $\hat{y}_i$ los valores predecidos por el modelo.

Para la implementación en el código se utiliza la función `mean_absolute_error`.

3.3.2 *Mean squared error (MSE)* o error cuadrático medio

Este término se refiere a la media del error cuadrático cometido por el modelo entre la variable esperada y y la variable predecida $\hat{y}$. Se calcula con la formula siguiente:

$$\mathrm{MSE}(y, \hat{y}) = \frac{1}{n_{\mathrm{samples}}} \sum_{i=0}^{n_{\mathrm{samples}}-1} (y_i - \hat{y}_i)^2$$

Para la implementación en el código se utiliza la función `mean_squared_error`.

3.3.3 R^2 o coeficiente de determinación

Este coeficiente determina la calidad del modelo para replicar los resultados, y la proporción de variación de los resultados que puede explicarse por este. Habitualmente esta métrica se presenta en el rango de cero a uno o expresado en tanto por ciento. El valor igual a uno explica una calidad excelente, el modelo se ajusta perfectamente a los datos. En cambio, valores cercanos a cero determinan un fracaso completo del modelo para estos datos.

Para la implementación en el código se utiliza la función `r2_score`.

Para el almacenamiento de los valores de las métricas aplicadas a distintos modelos se define un *dataframe* inicialmente vacío con los nombres de las columnas iguales a las siglas de las métricas:

[65]:
```
df_error = pd.DataFrame(columns =['modelo', 'MAE', 'MSE', 'R2'])

df_error
```

[65]:
```
Empty DataFrame
Columns: [modelo, MAE, MSE, R2]
Index: []
```

También se define una función para el almacenamiento de los errores en el dataframe:

[66]:
```
def function_error_save(nombre_modelo, y_predict, y_test = y_test):
    '''
    Función para la adición de valores en el dataframe de error.
    nombre_modelo:: el nombre del modelo que se ha aplicado para obtener␣
 ↪y_predict
    y_predict:: conjunto de salidas predecidas
    y_test:: conjunto de salidas esperadas
    df_error:: dataframe para almacenamiento de errores
    '''
    df_error_part = pd.DataFrame( data = {'modelo': nombre_modelo, 'MAE':
 ↪mean_absolute_error(y_test,y_predict), 'MSE':
 ↪mean_squared_error(y_test,y_predict),'R2':r2_score(y_test,y_predict)}, index␣
 ↪= [0])


    return df_error_part
```

Por tanto para almacenar los datos del modelo aplicado anteriormente (regresión lineal) deberemos aplicar la función y esta devolverá el *dataframe* de errores actualizado:

[67]:
```
df_error = df_error.append(function_error_save('LinearRegression', y_test,␣
 ↪y_predict))
df_error
```

[67]:

	modelo	MAE	MSE	R2
0	LinearRegression	1.913400e+11	7.982741e+25	-0.000077

Como se puede observar, los valores de errores son muy grandes. Por ello vamos a realizar pruebas con otros modelos y a aplicar la función para el almacenamiento de las métricas según el modelo.

3.4 Aplicación de modelos más complejos

Se han decidido aplicar dos modelos más complejos. Estos son: * Regresión *Ridge* * Regresión lineal generalizada

A continuación explicaremos cada una de ellas y se realizará el cálculo de los errores cometidos por ambas.

3.4.1 Regresión *Ridge*

Este modelo resuelve algunos de los problemas del modelo de regresión lineal clásico añadiendo una penalización al tamaño de los pesos según su valor. Esto lo hace minimizando la función:

$$\min_w ||Xw - y||_2^2 + \alpha||w||_2^2$$

Dónde α es la penalización sobre los pesos w.

[68]:
```
ridge = Ridge()
ridge.fit(X_train, y_train)
y_predict_ridge = ridge.predict(X_test)
ridge.coef_
```

[68]:
```
array([[-7.74888413e-03, -2.60039327e-02,  3.37416185e-02,
         3.20663681e-01,  9.40793319e-02, -8.72983503e-02,
        -1.90451144e-02,  2.51045830e-02,  0.00000000e+00,
        -1.26280276e-01,  1.43843821e-01, -2.93780595e-02,
         3.13165093e-01, -8.52095932e-03, -1.04924198e-02,
         1.14801570e-02,  5.95952658e-03,  3.28011184e-03,
        -1.21021814e-04,  6.62745324e-03, -6.64985408e-03,
        -1.22880869e-04,  7.34210992e-03,  5.35419880e-03,
        -8.05651730e-03,  8.10078122e-03,  1.66754117e-03,
        -1.21021814e-04,  1.84222122e-02,  8.66035649e-04,
        -4.24620318e-03,  1.95758139e-03, -1.12634655e-02,
         5.99468500e-03,  0.00000000e+00, -4.03662499e-03,
         6.29304386e-03,  1.76722434e-02,  8.53685159e-03,
         4.35954522e-03,  4.18674801e-03,  1.20819865e-02,
        -1.21021814e-04,  0.00000000e+00,  1.06952379e-02,
         3.09817449e-03,  6.65075974e-03, -1.21021814e-04,
         1.66832343e-02,  9.74944901e-03,  1.34438396e-02,
         8.95790693e-03, -1.15918543e-02,  1.05267259e-02,
        -1.36195578e-03,  1.63865751e-03, -6.64154677e-03,
        -3.44814675e-03,  1.43725390e-02, -1.20830619e-02,
         0.00000000e+00,  7.70763298e-03,  0.00000000e+00,
        -1.21021814e-04,  5.70497554e-03,  2.34618885e-03,
        -1.01746814e-02,  5.47693805e-03,  1.47694395e-02,
        -5.79179626e-03,  2.65129830e-03,  3.68871837e-03,
         0.00000000e+00, -1.82105939e-02,  3.62558175e-03,
         0.00000000e+00,  0.00000000e+00, -4.03651955e-03,
         3.94779642e-03, -3.32949680e-03,  8.64749971e-03,
         3.65417464e-03, -7.28303046e-03,  1.45937969e-03,
        -4.48904691e-03,  6.36864935e-03,  0.00000000e+00,
        -3.21348551e-03, -1.14036892e-02, -1.21021814e-04,
         1.84665245e-03,  0.00000000e+00,  4.28528576e-03,
        -1.38297833e-02,  3.85426118e-03, -5.46209626e-03,
         2.13811093e-03,  0.00000000e+00, -1.21021814e-04,
        -1.62269507e-02, -3.98065029e-03, -1.21021814e-04,
```

```
       -1.21021814e-04, -9.40061694e-03,  6.00508436e-04,
       -1.21739325e-02,  1.92726138e-02, -3.56937874e-05,
        2.14072124e-03, -3.85696994e-03,  1.34144185e-02,
       -8.59299340e-04, -3.40531636e-03,  0.00000000e+00,
        0.00000000e+00, -1.21021814e-04,  0.00000000e+00,
        9.38420765e-03,  0.00000000e+00, -1.84123492e-02,
        1.74557420e-03,  1.01190581e-02,  4.99845207e-03,
       -3.27494534e-03, -5.65392320e-03, -1.67568560e-02,
       -1.21021814e-04, -1.21021814e-04, -1.65679493e-02,
       -1.21021814e-04,  5.59448948e-03, -6.35541350e-03,
       -5.63950821e-03,  0.00000000e+00, -1.88774349e-03,
       -1.13816922e-02,  4.20086102e-03,  9.40886014e-03,
       -1.21021814e-04, -1.21021814e-04, -1.21021814e-04,
        1.69797331e-03,  6.87967123e-02, -2.75233263e-02,
       -9.01609702e-03,  3.02502251e-03, -1.27187353e-03,
        5.14520749e-03,  2.48975670e-02, -2.39801923e-02,
        1.36085036e-02, -5.17556396e-03,  2.94030674e-03,
        1.10251651e-02, -9.80091209e-03,  2.82202940e-02,
       -6.52063752e-03, -1.16366755e-02,  3.93384060e-03,
       -3.00012813e-03,  2.09051217e-03,  4.85780592e-02,
       -9.49353833e-03,  1.08499489e-02, -2.80145365e-02,
       -1.81138255e-02,  2.28351791e-02, -6.32122214e-03,
        1.32085899e-02, -1.21806268e-02,  6.85840412e-03,
       -1.37966297e-02, -6.04534859e-03, -1.14005054e-02,
       -3.16776343e-02,  1.80784058e-02, -1.51072443e-02,
        1.94261092e-02,  6.68748979e-03, -2.03334327e-02,
        9.06315266e-03,  8.87081723e-03, -1.09815657e-03,
       -9.73137968e-03, -6.23310411e-03,  1.87198130e-02,
        6.50920335e-04, -3.81091588e-02,  2.34372107e-03,
       -7.35742316e-03,  1.68011308e-02, -5.57925170e-03,
       -1.90409442e-02, -3.34549703e-02, -9.25264281e-03,
        3.09935002e-02,  1.70337014e-02, -4.67396039e-03]])
```

[69]:
```
df_error = df_error.append(function_error_save('Ridge', y_test,␣
 ↪y_predict_ridge))
df_error
```

[69]:

	modelo	MAE	MSE	R2
0	LinearRegression	1.913400e+11	7.982741e+25	-0.000077
0	Ridge	5.490676e-01	5.604845e-01	-0.020668

En este caso el error cometido es mucho menor y aunque R^2 esté dando valores extremadamente raros. Veamos otros modelos.

3.4.2 Regresión lineal generalizada

Este modelo es una extensión del modelo de regresión lineal. Los valores previstos se calculan a partir de una combinación lineal de las variables de entrada, mediante una función de enlace inversa llamada h:

$$\hat{y}(w, X) = h(Xw)$$

Además, la función a minimizar depende de una función de distribución de la familia exponencial (Normal, Poisson, Gamma, etc.). Esta dependencia queda explicitada por la función de desviación unitaria d. Por tanto el valor a minimizar vendrá dado por:

$$\min_w \frac{1}{2n_{\text{samples}}} \sum_i d(y_i, \hat{y}_i) + \frac{\alpha}{2}||w||_2,$$

Esta función a minimizar incluye la penalización de la función anterior sobre los pesos. De esta manera estamos aplicando un modelo más complejo que el anterior, pero manteniendo sus ventajas.

Para la implementación de este modelo se utiliza la función TweedieRegressor.

Para realizar una selección de la función de densidad coherente deberemos ver cómo es histograma de los datos según el precio:

[70]:
```
plt.hist(dfB.price, bins=30)
plt.title('Histograma de precio sin escalar')
plt.xlabel('Número de datos')
plt.xlabel('Precio')
```

[70]:
```
Text(0.5, 0, 'Precio')
```

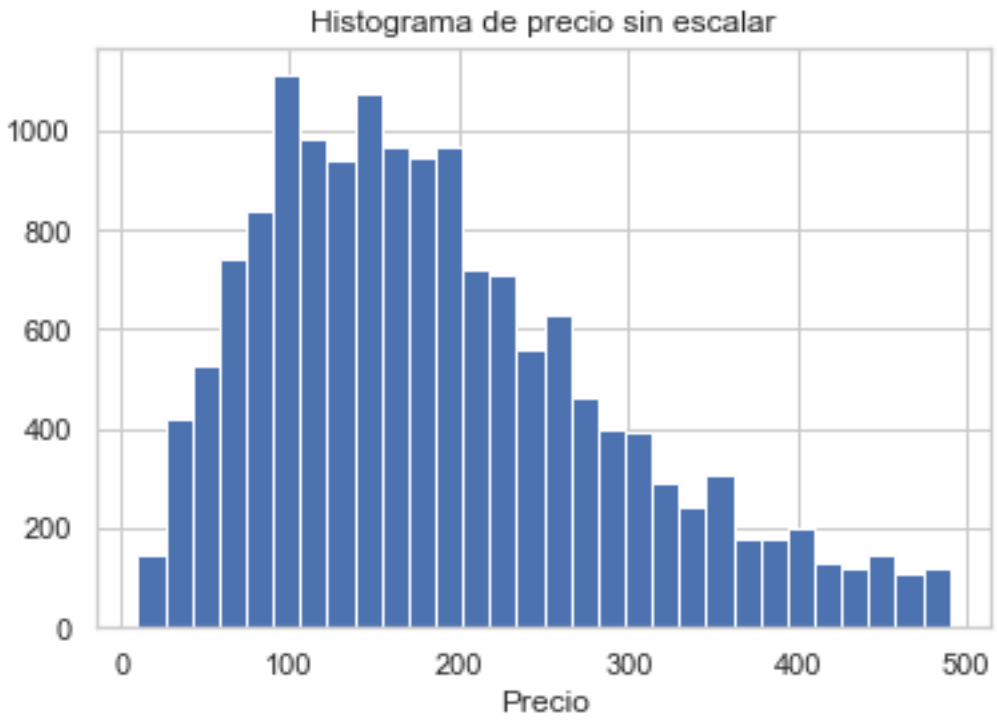

La función que más se aproxima a la forma de la densidad de datos es la de una normal, por tanto seleccionamos el parámetro "power" igual a 1.

[71]:
```
normal = TweedieRegressor(power=0)
normal.fit(X_train, y_train)
y_predict_normal = normal.predict(X_test)
df_error = df_error.append(function_error_save('Tweedie - Normal', y_test,␣
 ↪y_predict_normal))
df_error
```

[71]:

	modelo	MAE	MSE	R2
0	LinearRegression	1.913400e+11	7.982741e+25	-0.000077
0	Ridge	5.490676e-01	5.604845e-01	-0.020668
0	Tweedie - Normal	5.729425e-01	5.840309e-01	-0.852748

4 Análisis de errores

Gracias a la visualización del dataframe de los errores hemos podido ver cómo la métrica R^2 no ha sido útil en este caso, llegando a dar valores negativos, mientras que el MAE y el MSE se han ido modificando. A continuación visualizaremos los errores eliminando los valores de R^2 ya que no son útiles.

[72]:
```
df_error = df_error[['modelo', 'MAE','MSE']]
```

Se empieza por el MAE:

[73]:
```
sns.catplot(data=df_error, kind="bar",x='modelo', y='MAE')
```

[73]:
```
<seaborn.axisgrid.FacetGrid at 0x7f8d0e4bba50>
```

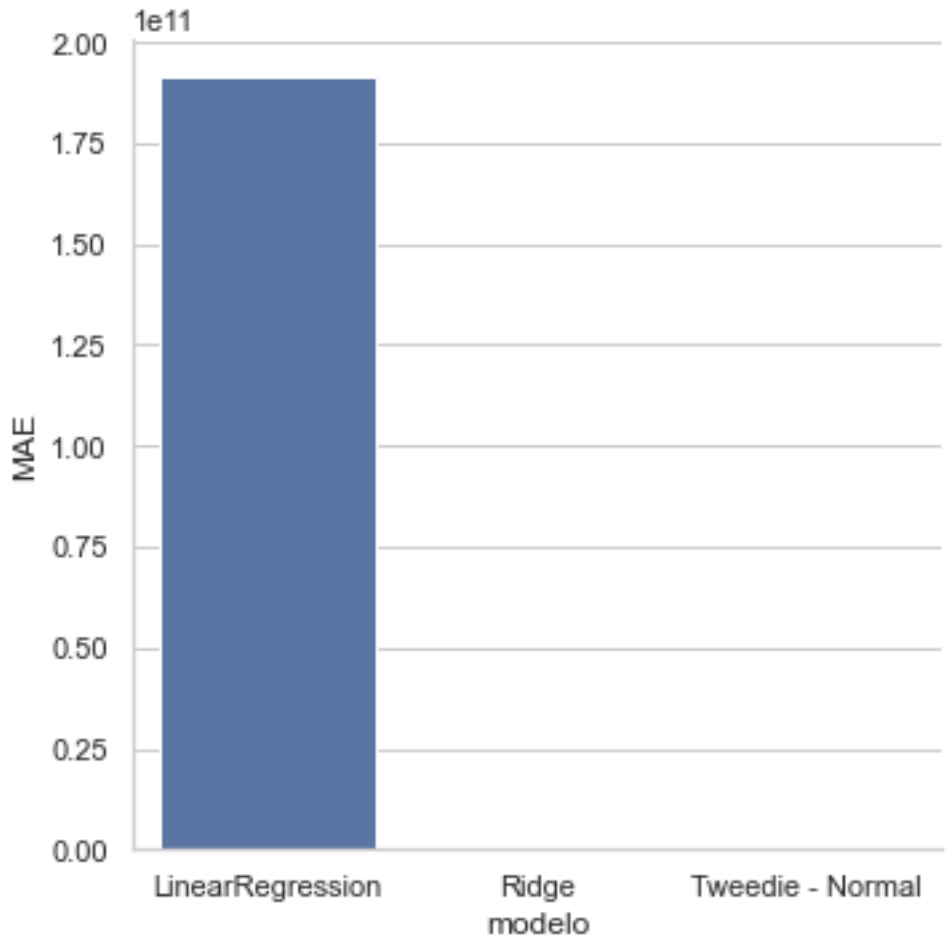

Como podemos ver, la regresion inicial comete errores muy grandes, así que vamos a descartarla a partir de este momento.

[74]:
```
df_error = df_error.loc[df_error.modelo != 'LinearRegression',:]
sns.catplot(data=df_error, kind="bar",x='modelo', y='MAE')
```

[74]:
```
<seaborn.axisgrid.FacetGrid at 0x7f8d0e65a390>
```

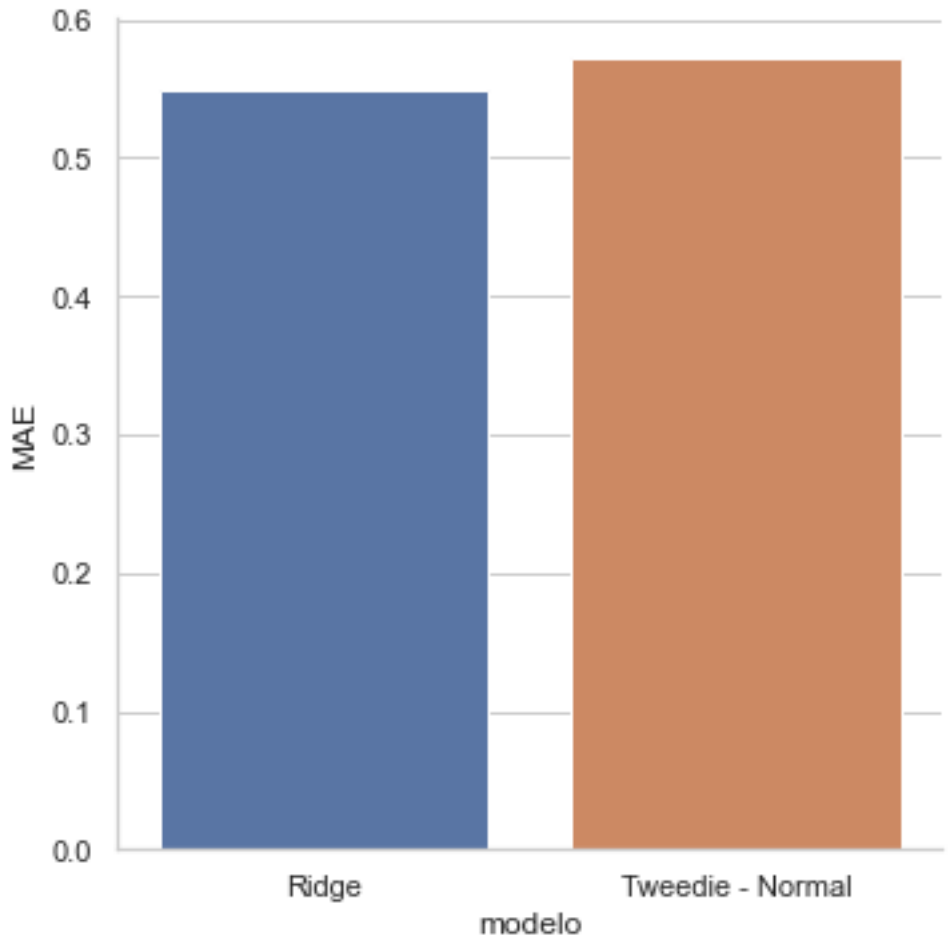

[75]:
```
sns.catplot(data=df_error, kind="bar",x='modelo', y='MSE')
```

[75]:
```
<seaborn.axisgrid.FacetGrid at 0x7f8d0e65f710>
```

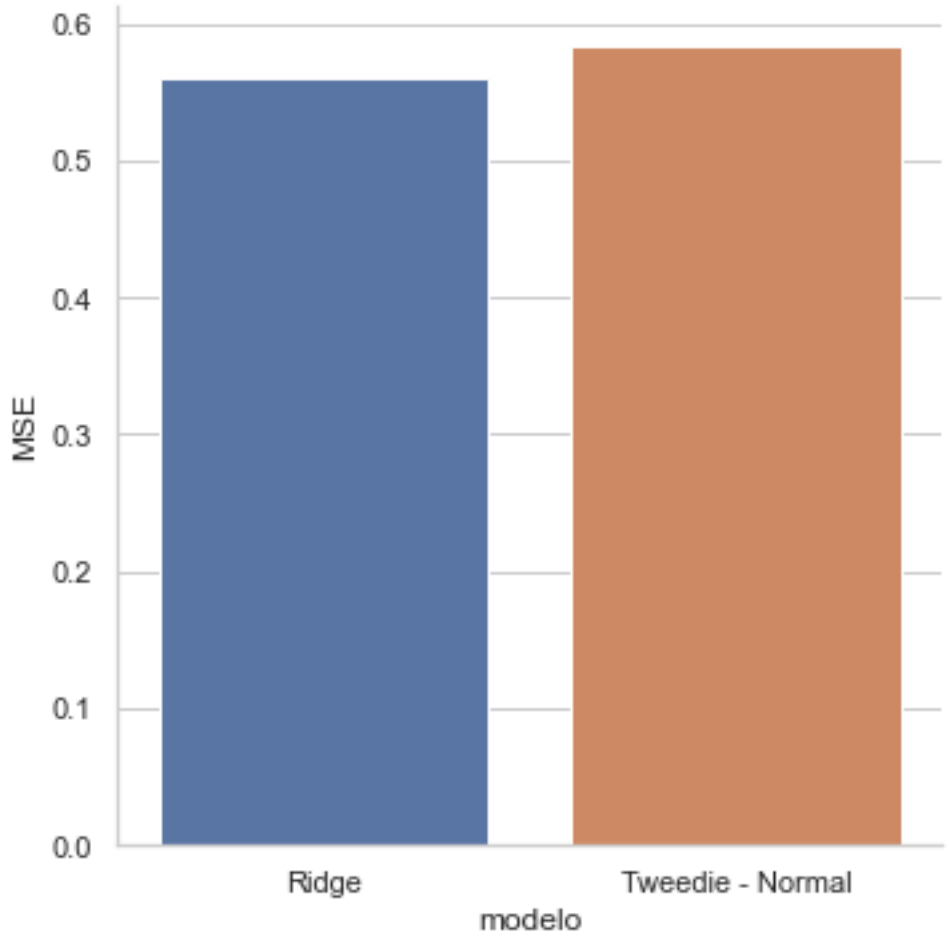

5 Resultado

Como se puede observar el modelo *Ridge* es el que da mejores resultados con ambas métricas. Por tanto es el modelo elegido para hacer la regresión del dataset de AirBNB.